

Análisis de series temporales mediante homología persistente y embedding por ventanas deslizantes

Autor:
Germán Garoz Tarjuelo

Director:
Diego Mondéjar Ruiz

Trabajo Fin de Grado en Ingeniería Matemática

2025-2026

Agradecimientos

A mis compañeros, y en especial a quienes empezaron siendo desconocidos y terminaron convirtiéndose en mis mejores amigos. Hay amistades que se forman en etapas como esta y que, precisamente por haber compartido tantos momentos importantes, acaban acompañándonos mucho más allá de esos años. Haber vivido esta parte del camino con vosotros ha sido una de las mejores cosas de la carrera, y espero que sea solo el comienzo de todo lo que todavía queda por compartir.

A los profesores que me han acompañado en CUNEF a lo largo de estos años, por haber sabido transmitir no solo conocimiento, sino también el entusiasmo por comprenderlo. Su forma de enseñar hizo que las matemáticas dejaran de ser únicamente una disciplina académica para convertirse en una fuente de curiosidad, interés y disfrute. Gracias por la dedicación, por la exigencia bien entendida y por haber despertado en mí una forma más profunda de acercarme a las matemáticas.

A Diego Mondéjar, mi tutor de TFG. Gracias por haberme propuesto un tema del que no sabía nada, por acompañarme durante todo este tiempo y por confiar en el trabajo incluso cuando yo mismo no lo tenía tan claro. De este proceso me llevo, más allá del contenido concreto del TFG, una forma distinta de aprender matemáticas, acercándome a un tema desconocido, intentando entenderlo poco a poco, investigando por mi cuenta y disfrutando del proceso de comprender algo simplemente por el interés que despierta.

Y a mis padres, sobre todo a mis padres, por haberme dado la oportunidad de estudiar lo que quería y por estar detrás de cada paso de estos años. Sin vuestro apoyo, en todos los sentidos, este trabajo no existiría. Gracias por confiar siempre.

Resumen

Este Trabajo de Fin de Grado aborda el problema de la detección de cambios de régimen en series temporales usando herramientas del análisis topológico de datos. El planteamiento será el siguiente: la forma local de una serie temporal puede medirse con herramientas de la topología algebraica, y esa medida sirve para identificar cuándo el comportamiento de la serie cambia.

La memoria está organizada en dos bloques:

El bloque teórico, formada por los capítulos 2 a 6, desarrolla el marco teórico necesario para llegar al método. En Capítulo 2 se introduce el análisis topológico de datos y por qué puede ser útil. El Capítulo 3 construye con detalle la homología simplicial. A continuación, el Capítulo 4 extiende esa construcción a la homología persistente, introduce los diagramas de persistencia y enuncia el Teorema de estabilidad de la distancia bottleneck. El Capítulo 5 presenta el embedding por ventanas deslizantes y su relación con el Teorema de Takens además del score SW1PerS de Perea y Harer. Finalmente, El Capítulo 6 adapta estas ideas al problema concreto de detectar cambios locales en una serie temporal: se desplaza una ventana a lo largo de la serie, se calcula un diagrama de persistencia en cada posición y se observa cómo cambian esos diagramas entre ventanas consecutivas.

La segunda parte se corresponde con el bloque práctico. En los capítulos 7 y 8 se pone el método a prueba. En el Capítulo 7 se trabaja primero con datos sintéticos, porque en ese caso se conoce de antemano el instante en el que cambia la señal. Esto nos permite comprobar de forma controlada si el procedimiento detecta cambios como la desaparición o la aparición de una componente periódica. Después, en el Capítulo 8, el método se aplica a una serie financiera real: el índice S&P500 alrededor de la crisis de 2008. Por último, para ampliar el análisis, se estudian también otros episodios bursátiles relevantes, como 1929, 1987, 2000, 2020 y 2022. En cinco de los seis casos analizados, el método señala un cambio de régimen cerca del evento de referencia. Además, los resultados se comparan con un detector más clásico basado en la varianza móvil, con el objetivo de entender mejor qué aporta el enfoque topológico.

Palabras clave: análisis topológico de datos, homología persistente, series temporales, embedding por ventanas deslizantes, detección de cambios, S&P 500.

Abstract

This Bachelor's Thesis addresses the problem of detecting regime changes in time series using tools from topological data analysis. The main idea is the following; the local shape of a time series can be measured through algebraic topology, and that measurement provides a way to identify when the behaviour of the series changes.

The text is organised in two parts:

The theoretical part, comprising chapters 2 to 6, develops the mathematical framework leading to the method. Chapter 2 introduces topological data analysis and motivates its usefulness. Chapter 3 builds simplicial homology in detail. Chapter 4 then extends that construction to persistent homology, introduces persistence diagrams and states the stability theorem for the bottleneck distance. Chapter 5 presents the sliding window embedding, its connection with Takens' theorem, and the SW1PerS score of Perea and Harer. Finally, Chapter 6 adapts these ideas to the specific problem of detecting local changes in a time series: a window is slid along the series, a persistence diagram is computed at each position, and the evolution of those diagrams between consecutive windows is monitored.

The second part corresponds to the practical block. chapters 7 and 8 put the method to the test. Chapter 7 works first with synthetic data, since in that setting the change point is known in advance. This allows us to check in a controlled way whether the procedure detects changes such as the disappearance or emergence of a periodic component. Chapter 8 then applies the method to a real financial series: the S&P 500 index around the 2008 crisis. To broaden the analysis, other relevant market episodes are also studied, including 1929, 1987, 2000, 2020 and 2022. In five of the six cases analysed, the method flags a regime change close to the reference event. The results are additionally compared to a classical detector based on the rolling variance, in order to better understand what the topological approach contributes.

Keywords: topological data analysis, persistent homology, time series, sliding window embedding, change point detection, S&P 500.

Índice general

Resumen	III
Abstract	IV
1. Introducción y estado del arte	1
1.1. Introducción y motivación	1
1.2. Estado del arte	1
1.3. Estructura de la memoria	2
2. Análisis topológico de datos (TDA)	3
2.1. ¿Qué problema queremos atacar?	3
2.2. De una nube de puntos a un objeto topológico	4
2.3. Funtorialidad	4
2.4. TDA: Análisis topológico de datos	5
3. Homología simplicial	7
3.1. Símplices y complejos simpliciales	7
3.2. Grupos de cadenas y operador borde	8
3.3. Ciclos, bordes y grupos de homología	9
3.4. Construcciones a partir de una nube de puntos	11
4. Homología persistente	13
4.1. Filtraciones	13
4.2. Homología persistente y números de Betti persistentes	13
4.3. Diagramas de persistencia y códigos de barras	14
4.4. Cálculo: el algoritmo de reducción matricial	16
4.5. Estabilidad	17
5. Análisis de series temporales mediante <i>sliding windows</i>	19
5.1. Series temporales y sistemas dinámicos	19
5.2. El embedding por ventanas deslizantes	20
5.3. Geometría del caso periódico	21
5.4. El método SW1PerS	22
6. Detección de cambios en series temporales mediante diagramas de persistencia	24
6.1. Del análisis global al análisis local	24
6.2. Construcción de la secuencia de diagramas	25
6.3. Parámetros del método	25
6.4. Comparación de diagramas consecutivos	26
6.5. Criterio de detección basado en un umbral	26

7. Experimentos con datos sintéticos	28
7.1. Señales sintéticas de partida	28
7.2. Embedding y diagramas	29
7.3. Score SW1PerS y robustez frente al ruido	30
7.4. Influencia de los parámetros del embedding	31
7.5. Detección de cambios sobre series sintéticas	31
7.5.1. Experimento 1: de señal periódica a ruido	32
7.5.2. Experimento 2: cambio de frecuencia	33
7.5.3. Experimento 3: de ruido a señal periódica	33
7.5.4. Interpretación conjunta	34
7.6. Conclusión del capítulo	34
8. Aplicación a una serie financiera real	35
8.1. Datos y preprocesado	35
8.2. Aplicación del método	36
8.3. Resultado del análisis	36
8.4. Validación sobre otros episodios históricos	37
8.5. Comparación con un detector clásico	38
8.6. Limitaciones y cierre del capítulo	40
9. Conclusiones y trabajo futuro	41
Bibliografía	43

1 Introducción y estado del arte

1.1 Introducción y motivación

El análisis de series temporales cuenta con muchas herramientas consolidadas. Modelos autorregresivos, suavizados exponenciales, descomposiciones espectrales o, más recientemente, redes neuronales recurrentes son utilizadas para predecir, suavizar o descomponer una señal. Sin embargo, en este trabajo nos interesa una pregunta algo distinta: *¿cuándo cambia el comportamiento de la serie?*. No buscamos una predicción puntual ni un ajuste global a toda la trayectoria, sino detectar el momento en el que la dinámica parece dejar de seguir el mismo patrón. Este tipo de problema aparece de forma natural en contextos muy distintos, como las finanzas, la sismología o la monitorización de procesos industriales.

El enfoque que vamos a seguir aquí parte del análisis topológico de datos. La idea básica consiste en transformar la serie temporal en una nube de puntos mediante un embedding por retardos. De este modo, cada tramo local de la serie queda representado por una nube cuya forma puede estudiarse con herramientas topológicas. Sobre esas nubes se calcula homología persistente, que permite medir la presencia de estructuras como ciclos o cavidades de forma estable frente a pequeñas perturbaciones. Al recorrer la serie con una ventana móvil se obtiene una sucesión de diagramas de persistencia; comparando diagramas consecutivos, se construye una señal auxiliar que mide cuánto cambia la forma local de la serie. Cuando esa señal supera un cierto umbral, interpretamos que puede haberse producido un cambio de régimen.

El interés del método es doble. Por un lado, permite conectar ideas de topología algebraica, sistemas dinámicos y análisis estadístico de series temporales. Por otro, se puede poner a prueba sobre datos reales, en particular sobre el índice S&P 500 alrededor de la crisis financiera de 2008. Esto permite comparar la salida del método con un episodio económico bien documentado y estudiar hasta qué punto la información topológica aporta una señal útil. Estos dos objetivos, entender la construcción matemática y comprobar su comportamiento en datos concretos, son los que organizan el resto de la memoria.

1.2 Estado del arte

El análisis topológico de datos arranca como campo independiente a mediados de los años dos mil. Una de las referencias principales es el artículo “*Topology and data*” de Carlsson [1], donde se plantea estudiar los datos como nubes de puntos y utilizar herramientas de la topología algebraica para extraer información cualitativa sobre su forma. En “*Barcodes*” de Ghrist [6] se presentan estas ideas de una manera especialmente visual, poniendo el foco en los códigos de barras de persistencia. Desde un punto de vista más técnico, el libro “*Computational Topology*” de Edelsbrunner y Harer [4] desarrolla con detalle la construcción de complejos, la homología persistente y el algoritmo matricial de reducción que permite calcular diagramas de persistencia. Además, el Teorema de estabilidad “*Stability of persistence diagrams*” de Cohen-Steiner, Edelsbrunner y Harer

[3] proporciona una justificación importante para el uso de estos métodos, al mostrar que pequeñas perturbaciones de los datos producen cambios controlados en los diagramas.

La conexión con series temporales aparece de forma destacada en el trabajo *“Sliding windows and persistence”* de Perea y Harer [9], donde se introduce el método SW1PerS. En ese artículo se utiliza el embedding por ventanas deslizantes, inspirado en la teoría de Takens, para transformar una señal temporal en una nube de puntos. Después se calcula la persistencia en dimensión uno para obtener una medida de periodicidad. Más adelante, en el artículo *“Topological time series analysis”* [8] se extienden estas ideas a señales cuasi-periódicas. En la misma línea *“Topological analysis for detecting anomalies”* Chazal, Levrard y Royer [2] proponen TADA, un detector topológico de anomalías para secuencias dependientes, con aplicación al análisis de series temporales. En la literatura financiera más reciente han aparecido trabajos que muestran cómo los descriptores topológicos calculados sobre ventanas móviles pueden ayudar a identificar movimientos bruscos del mercado.

El procedimiento que se estudia en esta memoria se sitúa dentro de esa línea. No se pretende introducir una técnica completamente nueva, sino combinar varias piezas ya existentes de forma coherente: el embedding por ventanas deslizantes, el cálculo de diagramas de persistencia y la comparación entre diagramas consecutivos para detectar cambios locales. La aportación del trabajo está en desarrollar el marco matemático necesario, implementar el procedimiento y comprobar su comportamiento en datos sintéticos y en una serie financiera real.

1.3 Estructura de la memoria

La memoria se organiza en dos bloques. La primera parte es teórica y va del Capítulo 2 al 6. En ella se introduce el análisis topológico de datos, después se construye la homología simplicial, y se extiende a homología persistente. A continuación se estudia el embedding por ventanas deslizantes y, finalmente, se presenta el procedimiento de detección de cambios que se utilizará en la parte práctica. La segunda parte corresponde a los experimentos y ocupa los capítulos 7 y 8: el primero valida el método sobre señales sintéticas con cambios de régimen conocidos y el segundo lo aplica al S&P 500 entre 2008 y 2009 y a otros cinco episodios bursátiles relevantes. El trabajo termina con un capítulo de conclusiones, donde se resumen los resultados obtenidos, se comentan las principales limitaciones y se proponen posibles líneas de continuación.

2 Análisis topológico de datos (TDA)

Este capítulo abre la parte matemática del trabajo. El desarrollo del trabajo se estructurará de manera progresiva: empezamos por la motivación general del análisis topológico de datos, y dejamos para los capítulos siguientes la construcción algebraica de la homología (Capítulo 3), su extensión a familias parametrizadas en forma de homología persistente (Capítulo 4) y, finalmente, el método de *sliding windows* (Capítulo 5) sobre el que descansa la aplicación a series temporales [9].

2.1 ¿Qué problema queremos atacar?

En la actualidad, muchos de los datos que aparecen en contextos científicos no se ajustan de forma natural a los moldes de la estadística clásica. Carlsson lo argumenta de forma muy directa en su artículo de 2009 [1]: los datasets actuales suelen tener dimensión muy alta, contienen ruido, una parte importante de las coordenadas no aporta información, y la métrica con la que se mide la distancia entre dos observaciones es a menudo poco más que una convención. En esa situación, la primera pregunta razonable no es cuantitativa sino cualitativa. Antes de calcular promedios o ajustar modelos uno querría saber, por ejemplo, si los datos forman un único grupo o varios; si tienen agujeros o cavidades; si parecen distribuirse sobre alguna superficie subyacente o son simplemente una nube sin forma.

Este tipo de preguntas es precisamente lo que estudia la topología, que se ocupa de las propiedades de los espacios que se conservan bajo deformaciones continuas. Si imaginamos una nube finita de puntos como una muestra (con algo de ruido) de cierto objeto geométrico que no vemos directamente, parece natural intentar adaptar las herramientas topológicas para extraer la forma de los datos. De ahí el nombre del campo: análisis topológico de datos, o TDA por sus siglas en inglés [1, 6].

Carlsson señala cuatro principios que justifican este enfoque y que vale la pena enunciar porque van a estar implícitos en el resto de los capítulos:

- La información cualitativa importa. Antes de cuantificar, hay que entender la organización a gran escala. Es muy distinto, por ejemplo, calcular medias en una población clínica si todavía no sabemos que en realidad está formada por dos subgrupos clínicamente distintos.
- Las métricas no siempre tienen una justificación teórica fuerte. En biología, ciencias sociales o procesamiento de imagen es habitual que las distancias se construyan a partir de medidas de similitud diseñadas a mano, y eso introduce una arbitrariedad de la que hay que ser conscientes.
- Las coordenadas tampoco tienen por qué ser “naturales”. Aunque los datos vengan en forma de vectores en $\mathbb{R}^n$, las coordenadas son a menudo el resultado del proceso de medida y no tienen un significado intrínseco.

- Los resúmenes a lo largo de un parámetro suelen ser más informativos que un único valor óptimo. Un ejemplo conocido es el del clustering jerárquico, que en lugar de devolver una partición fija proporciona un dendrograma con todas las particiones posibles [1].

La topología responde de forma bastante elegante a los tres primeros puntos: ignora la mayor parte de la información métrica fina, no depende de coordenadas y captura propiedades cualitativas. El cuarto requiere algo más, y es precisamente la idea de *persistencia*, que veremos en el Capítulo 4.

2.2 De una nube de puntos a un objeto topológico

La topología clásica trabaja con espacios continuos, pero un conjunto de datos es, por definición, finito y discreto. El primer paso, por tanto, es asociar a una nube finita un objeto topológico que tenga sentido. La pregunta es qué objeto.

La construcción habitual, descrita en Ghrist [6], consiste en pegar a la nube unos cuantos *trozos* elementales: a partir de los puntos, se añaden segmentos que unen pares cercanos; sobre tres puntos cercanos se rellena un triángulo; sobre cuatro, un tetraedro, y así sucesivamente. El resultado, una vez fijada una regla de proximidad, es un objeto combinatorio que mezcla piezas de varias dimensiones (vértices, aristas, triángulos, tetraedros, ...) pegadas de forma coherente: si una pieza está, también lo están todas sus caras, y dos piezas sólo pueden compartir caras completas, no cruzarse de cualquier manera. A este tipo de objeto se le llama **complejo simplicial**, y será nuestra herramienta principal a partir de ahora. La definición formal se dará en el Capítulo 3, pero con esta imagen geométrica basta para entender lo que sigue.

La construcción depende de una escala $\varepsilon \geq 0$. Fijado un valor de ε , dos puntos se consideran cercanos cuando la distancia entre ellos no supera ε , o bien, equivalentemente, cuando las bolas de radio $\varepsilon/2$ centradas en ellos se cortan. A partir de esa relación de proximidad se construye el complejo: los vértices son los puntos de la nube, dos puntos se unen por una arista si están cerca, tres puntos forman un triángulo cuando todos los pares lo están, y así sucesivamente. Variando ε obtenemos una familia de complejos cada vez más densa.

Las dos construcciones clásicas en TDA son el complejo de Čech y el complejo de Vietoris–Rips. Sus definiciones formales se dan en el capítulo III de Edelsbrunner y Harer [4] y nosotros las retomaremos en el Capítulo 3. Por ahora basta con quedarse con la idea: ambas construcciones traducen una nube de puntos en un complejo simplicial cuya forma topológica imita la del objeto subyacente, al menos para escalas razonables. Ahora bien, ¿cómo se elige el parámetro ε ? La respuesta corta es que no hay una elección óptima en general. Las dos elecciones extremas pierden información: eligiendo un ε muy pequeño el complejo apenas tiene aristas y reproduce la nube como un conjunto disperso de vértices; con ε muy grande casi todos los puntos quedan conectados y el complejo termina pareciéndose a un único símplice de dimensión alta.

2.3 Funtorialidad

La construcción que se ha desarrollado en este capítulo se crea sobre una idea que vamos a explicar antes de seguir: la **funtorialidad**. La introduciremos a través de un ejemplo elemental; la formulación rigurosa, en términos de morfismos inducidos en homología, se dará en el Capítulo 3. Conviene recordar primero qué se entiende por invariante

topológico. Un **invariante topológico** es una estructura asociada a un espacio que se mantiene cuando el espacio se deforma de manera continua, sin romperlo ni pegar partes que inicialmente son disjuntas. El número de componentes conexas es el ejemplo más sencillo de invariante topológico. Posteriormente estudiaremos ejemplos más complejos como los grupos de homología que se desarrollarán en el capítulo siguiente, estos detectan agujeros en distintas dimensiones. Volvamos ahora al primer ejemplo: contar las componentes conexas de un espacio. Si tenemos dos espacios K_1 y K_2 y una aplicación entre ellos

$$f : K_1 \longrightarrow K_2,$$

por ejemplo una inclusión $K_1 \hookrightarrow K_2$, parece natural pedir que f no solo mande puntos a puntos, sino que mande *componentes a componentes*. En efecto, si dos puntos están en la misma componente conexa de K_1 , sus imágenes deberían estar en la misma componente conexa de K_2 . Dicho de otro modo, la aplicación f induce de manera natural una aplicación entre los conjuntos de componentes conexas de uno y otro espacio.

Esta idea es un ejemplo sencillo de **funtorialidad**. Una observación conceptual del trabajo de Carlsson es que buena parte de la construcción de TDA se apoya precisamente en este principio: un invariante topológico funtorial no se limita a asignar un objeto algebraico a cada espacio, sino que asigna también una aplicación entre los invariantes cada vez que tenemos una aplicación entre los espacios, respetando además la composición [1].

Lo importante en este punto no es la formulación categórica exacta, sino la consecuencia que tendrá para la persistencia. Cuando en el Capítulo 4 estudiemos una familia anidada de complejos simpliciales

$$K_1 \subseteq K_2 \subseteq \cdots \subseteq K_n$$

y le apliquemos la homología, no obtendremos simplemente grupos aislados $H_p(K_i)$. Junto con cada inclusión obtendremos aplicaciones inducidas

$$H_p(K_i) \longrightarrow H_p(K_j), \quad i \leq j,$$

que nos permitirán seguir la evolución de las clases homológicas al pasar de un nivel al siguiente. En particular, estas aplicaciones nos dirán qué clases sobreviven, cuáles desaparecen y durante cuánto tiempo lo hacen. Sin esas aplicaciones inducidas, la noción de persistencia tal como la formalizaremos en el capítulo con dicho nombre 4 no estaría bien definida.

2.4 TDA: Análisis topológico de datos

Llegados a este punto conviene insistir en una observación que ya ha aparecido implícitamente. El análisis topológico de datos no consiste en aplicar un algoritmo concreto, sino en utilizar herramientas inspiradas en la topología para extraer características cualitativas de un conjunto de datos. Bajo este paraguas se han desarrollado varias técnicas. La más empleada, y la que articula este trabajo, es la **homología persistente** que trata de captar cómo nacen y mueren componentes, ciclos o cavidades a lo largo de una filtración. Sus resultados se representan mediante diagramas de persistencia y códigos de barras, objetos que se introducirán formalmente en el Capítulo de persistencia 4.

Otras herramientas, como Mapper el clustering funtorial o la persistencia multiparamétrica, también pertenecen al campo del TDA pero quedan fuera de los objetivos de este TFG, que se centra en la combinación de homología persistente con embeddings por ventanas deslizantes.

En los capítulos siguientes se desarrollará la base matemática necesaria para llegar a esa aplicación. En primer lugar, se construirá cuidadosamente la homología simplicial, ya que sin ella no es posible formular con precisión la homología persistente. A continuación, se introducirá la idea de filtración y se estudiará cómo la evolución de la homología a lo largo de una filtración se representa mediante códigos de barras, siguiendo a Edelsbrunner y Harer [4] y a Zomorodian y Carlsson [11]. Finalmente, se introducirá el análisis de señales mediante embeddings por retardo y *sliding windows*, siguiendo el método de Perea y Harer [9].

3 Homología simplicial

En el capítulo anterior hemos visto, en términos intuitivos, que una herramienta fundamental para asociar a una nube de puntos un objeto topológico es el complejo simplicial. En este capítulo se darán las definiciones con precisión y se construirá, sobre ellas, la maquinaria algebraica que va a permitir contar componentes, agujeros y cavidades. Esa maquinaria es la homología simplicial, y la desarrollamos siguiendo de cerca a Edelsbrunner y Harer [4] y a Hatcher [7].

3.1 Símplices y complejos simpliciales

Seguimos la formulación estándar de los símlices geométricos, como puede encontrarse en Edelsbrunner y Harer [4].

Definición 3.1. Sean $u_0, u_1, \dots, u_k \in \mathbb{R}^d$ puntos **afínmente independientes**, es decir, tales que los vectores $u_1 - u_0, \dots, u_k - u_0$ son linealmente independientes. El **k -símplice** generado por ellos es su envolvente convexa

$$\sigma = \text{conv}\{u_0, u_1, \dots, u_k\} = \left\{ \sum_{i=0}^k \lambda_i u_i : \lambda_i \geq 0, \sum_{i=0}^k \lambda_i = 1 \right\}.$$

Su dimensión es $\dim \sigma = k$.

La notación $\text{conv}\{u_0, \dots, u_k\}$ representa la envolvente convexa de estos puntos, es decir, el conjunto de todas sus combinaciones convexas. Geométricamente, esto equivale a tomar los vértices y rellenar todo lo que queda entre ellos.

La condición de independencia afín garantiza que el símplice no está degenerado: por ejemplo, tres puntos alineados no determinan un 2-símplice, sino un objeto de dimensión uno.

Para los primeros valores de k recuperamos los objetos geométricos habituales: un 0-símplice es un vértice, un 1-símplice una arista, un 2-símplice un triángulo relleno y un 3-símplice un tetraedro sólido. Cualquier subconjunto $\{u_{i_0}, \dots, u_{i_j}\}$ de los vértices de σ genera un nuevo símplice τ que es **cara** de σ , lo que escribimos $\tau \leq \sigma$. Si $\tau \neq \sigma$, hablamos de cara propia.

Definición 3.2. Un **complejo simplicial** (geométrico) es una colección finita K de símlices en $\mathbb{R}^d$ que satisface:

1. Si $\sigma \in K$ y $\tau \leq \sigma$, entonces $\tau \in K$ (cierre por caras).
2. Si $\sigma, \sigma' \in K$, entonces $\sigma \cap \sigma'$ es vacío o es una cara común de σ y de σ' .

La primera condición dice que no se puede incluir un símplice sin incluir también todas sus caras. Por ejemplo, si un complejo contiene un triángulo relleno, entonces debe contener también sus tres aristas y sus tres vértices.

La segunda condición impone que los símlices se peguen de forma compatible: dos símlices pueden no cortarse, compartir un vértice, compartir una arista o compartir una cara de mayor dimensión, pero no pueden intersectarse de manera arbitraria.

En la práctica suele ser más cómodo trabajar con la versión abstracta del complejo, en la que se ignoran las coordenadas y el complejo se codifica como una familia de subconjuntos finitos de un conjunto de vértices, cerrada por subconjuntos. Cualquier complejo abstracto admite una realización geométrica en algún $\mathbb{R}^d$ con d suficientemente grande, así que las dos formulaciones son equivalentes a efectos topológicos [4, Cap. III].

3.2 Grupos de cadenas y operador borde

Una vez definido el objeto geométrico sobre el que vamos a trabajar, el siguiente paso es asociarle objetos algebraicos que permitan medir sus agujeros.

Para construir la homología asociamos a cada complejo una sucesión de espacios vectoriales, uno por cada dimensión, conectados por aplicaciones lineales. A lo largo de todo el capítulo trabajaremos con coeficientes en el cuerpo $\mathbb{F}_2 = \mathbb{Z}/2\mathbb{Z}$. La elección no es accidental: los cálculos se vuelven más limpios al desaparecer los signos, las cadenas pueden interpretarse como subconjuntos de símlices, y muchos algoritmos computacionales de homología persistente se implementan de forma especialmente sencilla sobre este cuerpo.

Definición 3.3. Sea K un complejo simplicial finito y $p \geq 0$ entero. El **grupo de p -cadenas** de K , denotado $C_p(K)$, es el $\mathbb{F}_2$ -espacio vectorial generado por los p -símlices de K . Un elemento de $C_p(K)$ es una suma formal $c = \sum_i a_i \sigma_i$, donde cada $a_i \in \mathbb{F}_2$ y los σ_i recorren los p -símlices.

Como $a_i \in \{0, 1\}$, una p -cadena se puede leer también como una colección finita de p -símlices: aquellos cuyo coeficiente vale 1. Por ejemplo, si K contiene las aristas $[u_0, u_1]$, $[u_1, u_2]$ y $[u_0, u_2]$, la suma

$$[u_0, u_1] + [u_1, u_2]$$

es la 1-cadena formada por las dos primeras aristas. En adelante usaremos indistintamente las dos perspectivas, según convenga.

Para conectar las cadenas de dimensiones consecutivas necesitamos un operador lineal que asocie a cada símplex su borde. Siguiendo a Edelsbrunner y Harer [4, Cap. IV], definimos, para cada $p \geq 1$, el **operador borde**

$$\partial_p : C_p(K) \longrightarrow C_{p-1}(K),$$

sobre los generadores como la suma de sus caras de codimensión uno. En coeficientes enteros la fórmula clásica incluye signos alternados, pero al trabajar en $\mathbb{F}_2$ estos signos resultan irrelevantes, ya que $1 + 1 = 0$, y la expresión se simplifica a

$$\partial_p [u_0, u_1, \dots, u_p] = \sum_{i=0}^p [u_0, \dots, \widehat{u_i}, \dots, u_p], \quad (3.1)$$

donde $\widehat{u_i}$ indica que se omite el vértice u_i .

Aquí el símbolo $\widehat{u_i}$ indica que el vértice u_i se omite. Por tanto, cada término de la suma es una cara de dimensión $p - 1$ del símplex original. La aplicación se extiende después por linealidad a cualquier p -cadena.

Geométricamente, $\partial_p \sigma$ es la suma de las caras de codimensión uno de σ . Por ejemplo, si $p = 1$, el borde de la arista $[u_0, u_1]$ es

$$\partial_1 [u_0, u_1] = [u_1] + [u_0].$$

Es decir, el borde de una arista está formado por sus dos extremos.

Si $p = 2$, el borde del triángulo $[u_0, u_1, u_2]$ es

$$\partial_2[u_0, u_1, u_2] = [u_1, u_2] + [u_0, u_2] + [u_0, u_1],$$

que corresponde a la suma de sus tres aristas.

La propiedad clave del operador borde es que el borde de un borde siempre se cancela. En términos algebraicos, esto significa que la composición de dos operadores borde consecutivos es la aplicación nula.

Lema 3.4 (El borde del borde es cero). *Para todo $p \geq 1$, se cumple*

$$\partial_{p-1} \circ \partial_p = 0.$$

La idea de la demostración es que cada cara de dimensión $p - 2$ aparece dos veces al aplicar el borde dos veces, y como trabajamos en $\mathbb{F}_2$, esas dos apariciones se cancelan.

Demostración. Por linealidad basta comprobarlo sobre un único p -símplice $\sigma = [u_0, \dots, u_p]$. Su borde $\partial_p \sigma$ es la suma de los $p + 1$ símlices que se obtienen omitiendo cada uno de los vértices. Al aplicar ∂_{p-1} a cada uno de estos términos obtenemos sumas de símlices de dimensión $p - 2$. Una cara $(p - 2)$ -dimensional cualquiera de σ se obtiene omitiendo dos vértices distintos u_i y u_j , y aparece *exactamente dos veces* en el doble borde: una al eliminar primero u_i y después u_j , y otra en el orden contrario. Como estamos trabajando en $\mathbb{F}_2$, esos dos términos suman cero. Sumando sobre todas las caras $(p - 2)$ -dimensionales se obtiene

$$\partial_{p-1}(\partial_p \sigma) = 0.$$

□

3.3 Ciclos, bordes y grupos de homología

Con el operador borde y el lema 3.4 ya podemos formalizar algebraicamente la idea de “agujero”.

Definición 3.5. *Sea K un complejo simplicial finito y sea $p \geq 0$. El grupo de p -**ciclos** es*

$$Z_p(K) := \ker \partial_p,$$

*y el grupo de p -**bordes** es*

$$B_p(K) := \operatorname{Im} \partial_{p+1}.$$

Por el lema 3.4, se tiene que

$$B_p(K) \subseteq Z_p(K).$$

Por tanto, el p -ésimo grupo de homología de K está bien definido como el cociente

$$H_p(K) := Z_p(K) / B_p(K).$$

Su dimensión como $\mathbb{F}_2$ -espacio vectorial,

$$\beta_p(K) := \dim H_p(K),$$

se denomina p -ésimo número de Betti de K .

El cociente $Z_p(K)/B_p(K)$ es muy importante dentro de la construcción: al identificar con cero todos los ciclos que provienen como borde de una $(p+1)$ -cadena, lo que sobrevive en $H_p(K)$ son las clases de ciclos que no han quedado rellenos por ninguna celda de dimensión inmediatamente superior, es decir, agujeros no triviales.

Veamos cuál será la intuición geométrica. Los p -ciclos de $Z_p(K)$ son cadenas cerradas de dimensión p que, sin más información, serían candidatas a rodear un agujero. Algunos de esos ciclos se anulan al descender al cociente porque ya han sido rellenos por $(p+1)$ -celdas: son los elementos de $B_p(K)$ que no aportan información topológica. En particular, β_0 se interpreta como el número de componentes conexas del complejo; β_1 recoge los lazos independientes que no son frontera de ninguna superficie del complejo, y β_2 corresponde a cavidades tridimensionales, entendidas como regiones huecas encerradas por superficies. Los ejemplos clásicos son la esfera S^2 , con $\beta_2 = 1$ por la cavidad que encierra, y el toro T^2 , que además satisface $\beta_1 = 2$ por sus dos lazos independientes (el meridiano y el paralelo).

Ejemplo 3.6 (Triángulo hueco frente a triángulo relleno). *Tomemos los vértices $\{1, 2, 3\}$ y las aristas*

$$e_1 = [1, 2], \quad e_2 = [2, 3], \quad e_3 = [1, 3].$$

Sea K el complejo formado por estos seis símplexes, es decir, los tres vértices y las tres aristas, pero sin el triángulo relleno. Sea K' el complejo que además incluye el 2-símplex

$$T = [1, 2, 3].$$

En ambos casos el complejo es conexo, así que $\beta_0 = 1$. Para estudiar la dimensión 1, calculamos la matriz de ∂_1 tomando como base (e_1, e_2, e_3) en C_1 y $([1], [2], [3])$ en C_0 . Como

$$\partial_1 e_1 = [1] + [2], \quad \partial_1 e_2 = [2] + [3], \quad \partial_1 e_3 = [1] + [3],$$

la matriz de ∂_1 es

$$[\partial_1] = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}.$$

Esta matriz tiene rango 2.

Recordemos el teorema del rango y la nulidad de álgebra lineal: si $T : V \rightarrow W$ es una aplicación lineal entre espacios vectoriales de dimensión finita, entonces

$$\dim V = \dim \ker T + \text{rank } T.$$

Aplicado al operador borde

$$\partial_1 : C_1 \rightarrow C_0,$$

obtenemos

$$\dim C_1 = \dim \ker \partial_1 + \text{rank } \partial_1.$$

Despejando,

$$\dim \ker \partial_1 = \dim C_1 - \text{rank } \partial_1.$$

Como $Z_1 = \ker \partial_1$, se sigue que

$$\dim Z_1 = \dim \ker \partial_1 = \dim C_1 - \text{rank } \partial_1 = 3 - 2 = 1.$$

Un generador de Z_1 es la cadena

$$z = e_1 + e_2 + e_3.$$

En K no hay 2-símplices, luego

$$B_1(K) = 0.$$

Por tanto,

$$H_1(K) = Z_1(K)$$

y

$$\beta_1(K) = 1.$$

Así, el ciclo z representa el agujero del triángulo hueco.

En cambio, en K' se tiene

$$\partial_2 T = e_1 + e_2 + e_3 = z.$$

Por tanto,

$$B_1(K') = \langle z \rangle = Z_1(K').$$

De este modo,

$$H_1(K') = 0$$

y, en consecuencia,

$$\beta_1(K') = 0.$$

El ciclo ha quedado rellenado por el 2-símplice T .

La diferencia entre K y K' no está en la existencia del ciclo z , que aparece en ambos complejos, sino en si dicho ciclo es o no borde de un 2-símplice.

Este ejemplo sencillo contiene en miniatura la dinámica que se estudiará en el Capítulo 4: al añadir un símplex de dimensión superior, una clase de homología puede “morir”. La homología persistente consiste, esencialmente, en seguir el rastro de cuándo nacen y cuándo mueren las clases a lo largo de una familia parametrizada de complejos.

3.4 Construcciones a partir de una nube de puntos

Volvamos al problema que nos interesa: a una nube finita $X \subseteq \mathbb{R}^d$ queremos asociarle un complejo simplicial cuya forma topológica refleje la del objeto subyacente. Las dos construcciones canónicas dependen de un parámetro de escala $\varepsilon \geq 0$ y son las siguientes [4, 6].

Definición 3.7. El **complejo de Čech** de la nube X con escala ε , denotado $\check{C}_\varepsilon(X)$, es el complejo simplicial abstracto cuyos k -símplices son los subconjuntos $\{x_0, \dots, x_k\} \subseteq X$ tales que las bolas cerradas de radio $\varepsilon/2$ centradas en los x_i tienen intersección común no vacía:

$$\bigcap_{i=0}^k \overline{B}(x_i, \varepsilon/2) \neq \emptyset.$$

Definición 3.8. El **complejo de Vietoris–Rips** de la nube X con escala ε , denotado $\text{VR}_\varepsilon(X)$, es el complejo simplicial abstracto cuyos k -símplices son los subconjuntos $\{x_0, \dots, x_k\} \subseteq X$ tales que la distancia entre cada par de ellos es a lo sumo ε :

$$\|x_i - x_j\| \leq \varepsilon \quad \text{para todo } 0 \leq i, j \leq k.$$

La diferencia entre ambas construcciones es sutil pero importante. Para que un s mplice est e en el complejo de  ech necesitamos una condici n *global*: las bolas tienen que cortarse *todas a la vez*. Para Vietoris–Rips basta con una condici n *por pares*: la informaci n de las distancias entre puntos determina por completo el complejo. En la pr ctica esto hace que Vietoris–Rips sea mucho m s sencillo de calcular, ya que basta con almacenar el grafo de aristas.

En otras palabras, el complejo de Vietoris–Rips se obtiene a partir del grafo de proximidad rellenando todos los subconjuntos de v rtices que est n conectados dos a dos. Es decir, si tres puntos est n unidos entre s  por aristas, se a ade el tri ngulo correspondiente; si cuatro puntos est n unidos dos a dos, se a ade el tetraedro correspondiente; y as  sucesivamente.

A cambio de la sencillez, el complejo de Vietoris–Rips puede no tener el mismo tipo de homotop a que el complejo de  ech para el mismo ε . De forma informal, dos espacios tienen el mismo tipo de homotop a si uno puede deformarse continuamente en el otro sin cortar ni pegar partes esenciales. En particular, espacios con el mismo tipo de homotop a tienen la misma homolog a. Sin embargo, ambos est n relacionados de manera muy controlada.

Lema 3.9 (Comparaci n entre  ech y Vietoris–Rips). *Dada una nube finita $X \subseteq \mathbb{R}^d$, las filtraciones de  ech y de Vietoris–Rips est n relacionadas mediante inclusiones de complejos simpliciales. En particular, para todo $\varepsilon \geq 0$, con la convenci n de escala adoptada, se tiene*

$$\check{C}_\varepsilon(X) \subseteq \text{VR}_\varepsilon(X),$$

y existe una constante $c > 0$, dependiente del espacio ambiente y de la convenci n de escala, tal que

$$\text{VR}_\varepsilon(X) \subseteq \check{C}_{c\varepsilon}(X).$$

La primera inclusi n es inmediata: si las bolas cerradas de radio $\varepsilon/2$ centradas en los puntos $x_0, \dots, x_k$ tienen intersecci n com n no vac a, entonces, en particular, cualquier par de esas bolas se corta. Por tanto, la distancia entre cualesquiera dos centros es a lo sumo ε , y el mismo subconjunto de puntos define un s mplice en $\text{VR}_\varepsilon(X)$.

La segunda inclusi n expresa que un conjunto de puntos cuyas distancias dos a dos est n acotadas por ε queda contenido en una bola de radio comparable a ε . En otras palabras, un s mplice de Vietoris–Rips a escala ε aparece tambi n como s mplice de  ech a una escala mayor, salvo por una constante multiplicativa. La demostraci n precisa requiere una estimaci n geom trica sobre el radio de una bola que contiene a un conjunto de di metro acotado, y puede consultarse en Edelsbrunner y Harer [4]. Para nuestros fines, lo importante no ser  el valor exacto de la constante, sino el hecho de que ambas construcciones se aproximan de manera controlada.

La importancia de esta comparaci n es que, al pasar a la homolog a persistente, las caracter sticas topol gicas detectadas por Vietoris–Rips pueden interpretarse como aproximaciones computacionalmente manejables de las que aparecer an en el complejo de  ech, que est  m s directamente relacionado con la uni n de bolas.

4 Homología persistente

Hasta aquí hemos definido la homología de un complejo simplicial fijo. Sin embargo, como vimos en el Capítulo 2, en TDA no trabajamos con un único valor de ε , sino con una familia de complejos parametrizada por la escala. La homología persistente es la herramienta que permite seguir, a lo largo de esa familia, qué características topológicas permanecen durante un rango amplio de escalas y cuáles tienen una vida corta.

4.1 Filtraciones

Definición 4.1. Una **filtración finita** de un complejo simplicial K es una sucesión creciente de subcomplejos

$$\emptyset = K_0 \subseteq K_1 \subseteq K_2 \subseteq \cdots \subseteq K_n = K.$$

La condición de ser creciente significa que ninguna de las inclusiones $K_i \subseteq K_{i+1}$ retira simplices: es decir, si un simplex está en K_i , sigue estando en todo K_j con $j \geq i$. Al pasar de un nivel al siguiente, lo que ocurre es que algunos simplices nuevos (como vértices, aristas, ...) se añaden al complejo. Esta propiedad de anidamiento es la que va a permitir, mediante la funtorialidad de la homología, comparar $H_p(K_i)$ con $H_p(K_j)$ a través de la aplicación inducida por la inclusión.

El ejemplo prototípico es la filtración de Vietoris–Rips de una nube finita X . Si consideramos una sucesión creciente de escalas

$$0 = \varepsilon_0 < \varepsilon_1 < \cdots < \varepsilon_n,$$

entonces la familia

$$\text{VR}_{\varepsilon_0}(X) \subseteq \text{VR}_{\varepsilon_1}(X) \subseteq \cdots \subseteq \text{VR}_{\varepsilon_n}(X)$$

es una filtración: al aumentar ε se añaden aristas y simplices de dimensión superior, pero ninguno se elimina. La filtración de Čech es construida de manera similar.

4.2 Homología persistente y números de Betti persistentes

Tal como se anticipó al hablar de funtorialidad en el Capítulo 2, cada inclusión $K_i \hookrightarrow K_j$ con $i \leq j$ no se queda en una mera relación entre los complejos: también induce, por construcción, una aplicación lineal entre los grupos de homología,

$$\iota_p^{i,j} : H_p(K_i) \longrightarrow H_p(K_j).$$

Esta aplicación es la herramienta que permite trasladar las clases de homología desde un nivel al siguiente. Una clase $\gamma \in H_p(K_i)$ que sigue siendo no nula al pasar por $\iota_p^{i,j}$ es una

clase que sobrevive hasta el nivel j ; si en algún momento del recorrido se convierte en borde de una $(p+1)$ -cadena, deja de ser representable como clase no trivial y diremos que ha muerto.

Definición 4.2. Sea $\{K_i\}_{i=0}^n$ una filtración. Para cada par de índices $0 \leq i \leq j \leq n$ y cada $p \geq 0$, el p -ésimo **grupo de homología persistente** entre los niveles i y j se define como la imagen de la aplicación inducida,

$$H_p^{i,j} := \text{Im}(\iota_p^{i,j}) \subseteq H_p(K_j).$$

Su dimensión, $\beta_p^{i,j} := \dim H_p^{i,j}$, recibe el nombre de **número de Betti persistente entre los niveles i y j** .

La interpretación es directa: $H_p^{i,j}$ recoge las clases de homología p -dimensional que nacen no más tarde que el nivel i y que siguen siendo no triviales al llegar al nivel j . Las clases que se han convertido en borde antes de llegar a K_j no aparecen en esta imagen.

Conviene también introducir el lenguaje de nacimientos y muertes, que es como se interpreta la persistencia en la práctica. Diremos que una clase nace en el nivel i cuando aparece por primera vez como una nueva clase de homología, es decir, cuando no proviene de ningún nivel anterior.

Diremos que muere en el nivel j si su imagen deja de representar una clase independiente en $H_p(K_j)$. Esto puede ocurrir, por ejemplo, porque se convierte en borde de una cadena de dimensión $p+1$ o, en dimensión 0, porque una componente se fusiona con otra nacida antes. En caso de fusión, se utiliza la llamada *regla del más viejo*: sobrevive la clase que nació antes y muere la más joven [4].

Si una clase nace en el nivel i y muere en el nivel j , su persistencia se mide por la diferencia entre los parámetros de muerte y nacimiento. Intuitivamente, cuanto mayor es esta diferencia, más robusta se considera la característica topológica detectada.

Ejemplo 4.3 (Nacimiento y muerte en un triángulo). Consideremos una filtración

$$K_0 \subseteq K_1 \subseteq K_2$$

en la que K_0 contiene tres vértices y dos aristas, K_1 añade la tercera arista cerrando el borde de un triángulo, y K_2 añade el 2-símplice que rellena ese triángulo.

En K_0 no hay ciclos de dimensión 1. Al pasar a K_1 , aparece un ciclo formado por las tres aristas del triángulo; por tanto, nace una clase en $H_1(K_1)$. Al añadir el 2-símplice en K_2 , ese ciclo pasa a ser borde del triángulo relleno, de modo que la clase muere en K_2 .

Así, esta clase de homología persistente tiene intervalo de vida

$$[1, 2).$$

En términos geométricos, el agujero existe en el nivel 1, pero desaparece al llegar al nivel 2.

4.3 Diagramas de persistencia y códigos de barras

La información de persistencia de un complejo filtrado puede representarse de dos formas estrechamente relacionadas: mediante **códigos de barras** y mediante **diagramas de persistencia**. En el código de barras, cada clase homológica se representa por un intervalo $[b, d)$, donde b indica el nivel en el que la clase nace y d el nivel en el que muere. En el diagrama de persistencia, ese mismo intervalo se representa por el punto (b, d) en el plano nacimiento-muerte.

Ambas representaciones codifican la misma información, pero la muestran de manera diferente: los códigos de barras son especialmente intuitivos para visualizar la duración de las clases, mientras que los diagramas de persistencia son más cómodos para comparar conjuntos de datos y definir distancias entre resúmenes persistentes.

Definición 4.4. *El **código de barras** de dimensión p asociado a una filtración es la colección de intervalos*

$$[b, d)$$

que representan la vida de las clases de homología de dimensión p . El extremo izquierdo b indica el nivel en el que nace la clase, mientras que el extremo derecho d indica el nivel en el que muere. Si una clase no muere dentro de la filtración considerada, se representa mediante un intervalo de la forma $[b, \infty)$.

Definición 4.5. *El **diagrama de persistencia** de dimensión p asociado a una filtración, denotado Dgm_p , es el multiconjunto de puntos*

$$(b, d) \in \overline{\mathbb{R}}^2, \quad \overline{\mathbb{R}} = \mathbb{R} \cup \{\infty\}, \quad b \leq d,$$

donde cada punto representa una clase de homología de dimensión p que nace en b y muere en d . De este modo, el intervalo $[b, d)$ del código de barras se representa en el diagrama mediante el punto (b, d) .

Si queremos estudiar la distancia entre diagramas se añade la diagonal $\Delta = \{(x, x)\}$. Esto garantiza que siempre exista una biyección entre los diagramas a comparar.

Las dos representaciones contienen la misma información, pero la muestran de forma distinta. En el código de barras, las clases con vida larga aparecen como barras largas, mientras que en el diagrama de persistencia aparecen como puntos alejados de la diagonal. De la misma manera, las que tienen una vida breve aparecen como barras cortas o puntos cercanos a la diagonal.

En aplicaciones, las barras largas suelen interpretarse como rasgos topológicos robustos, mientras que las barras cortas suelen asociarse a ruido, discretización o a fenómenos de escala pequeña [6].

La razón por la que la información persistente puede representarse mediante una colección de intervalos no es trivial. Descansa en un teorema de estructura para módulos de persistencia, debido a Zomorodian y Carlsson [11].

Teorema 4.6 (Estructura de los módulos de persistencia). *Sea $\mathbb{F}$ un cuerpo y consideremos una filtración finita de complejos simpliciales. Para cada dimensión p , la homología persistente asociada a la filtración puede interpretarse como un módulo graduado finitamente generado sobre el anillo de polinomios $\mathbb{F}[t]$. Dicho módulo se descompone, de manera única salvo reordenación, como suma directa de módulos intervalo. En consecuencia, la información persistente queda determinada por una colección de intervalos*

$$[b_i, d_i),$$

que forman el código de barras.

La idea algebraica es que la acción de la variable t representa el paso de un nivel de la filtración al siguiente. Los sumandos de la descomposición anterior codifican clases que nacen en un cierto nivel y mueren en otro. Los intervalos finitos $[b_i, d_i)$ corresponden a clases que mueren, mientras que los intervalos infinitos $[b_i, \infty)$ corresponden a clases que permanecen vivas hasta el final de la filtración.

Una consecuencia práctica es que los números de Betti persistentes pueden leerse directamente a partir del código de barras.

Corolario 4.7. *El número de Betti persistente $\beta_p^{i,j}$ es igual al número de barras $[b, d)$ del código de barras de dimensión p tales que*

$$b \leq i \leq j < d.$$

Es decir, $\beta_p^{i,j}$ cuenta las clases de dimensión p que ya han nacido en el nivel i y que siguen vivas al llegar al nivel j . En el código de barras, esto equivale a contar las barras que contienen simultáneamente los niveles i y j , o equivalentemente, todo el intervalo discreto entre ambos.

4.4 Cálculo: el algoritmo de reducción matricial

El cálculo del diagrama de persistencia es, esencialmente, un problema de álgebra lineal sobre $\mathbb{F}_2$ [5, 4]. La idea es codificar toda la información de la filtración en una única matriz de borde y reducirla mediante operaciones elementales por columnas.

Sea

$$K_0 \subseteq K_1 \subseteq \cdots \subseteq K_n$$

una filtración finita. Ordenamos todos los símlices del complejo final K_n según el momento en que aparecen en la filtración, imponiendo además que toda cara aparezca antes que el símplex que la contiene. Es decir, si τ es una cara de σ , entonces τ debe aparecer antes que σ en el orden elegido. Esta condición garantiza que el borde de un símplex sólo involucra símlices anteriores.

Una vez fijado este orden, se construye una matriz de borde ∂ cuyas filas y columnas están indexadas por los símlices de la filtración. La columna correspondiente a un símplex σ_j contiene los coeficientes de su borde $\partial\sigma_j$ escritos en la base formada por los símlices ordenados. Como trabajamos sobre $\mathbb{F}_2$, las entradas de la matriz son únicamente 0 o 1.

El algoritmo reduce esta matriz por columnas, de izquierda a derecha. Llamaremos **pivote** de una columna no nula a la fila de índice más alto en la que dicha columna tiene un 1. Si una columna tiene el mismo pivote que una columna anterior, se suma la columna anterior a la actual para cancelar ese pivote. Como los coeficientes están en $\mathbb{F}_2$, sumar dos columnas equivale a hacer la suma módulo 2, de modo que $1 + 1 = 0$.

El proceso continúa hasta que se cumple la siguiente condición: cada columna reducida es nula o tiene un pivote distinto del pivote de cualquier otra columna no nula anterior. Una vez reducida la matriz, los pares nacimiento–muerte se leen de la siguiente manera. Si la columna j tiene pivote en la fila i , entonces el símplex σ_i crea una clase homológica y el símplex σ_j la destruye. Por tanto, el par (i, j) representa una clase que nace cuando aparece σ_i y muere cuando aparece σ_j .

Ejemplo 4.8 (Reducción en una filtración triangular). *Consideremos una filtración formada por tres vértices, tres aristas y un triángulo relleno. Ordenamos los símlices como*

$$\sigma_1 = [1], \quad \sigma_2 = [2], \quad \sigma_3 = [3], \quad \sigma_4 = [1, 2], \quad \sigma_5 = [2, 3], \quad \sigma_6 = [1, 3], \quad \sigma_7 = [1, 2, 3].$$

Los tres primeros símlices son vértices, por lo que sus bordes son cero. Los bordes de las aristas son

$$\partial\sigma_4 = \sigma_1 + \sigma_2, \quad \partial\sigma_5 = \sigma_2 + \sigma_3, \quad \partial\sigma_6 = \sigma_1 + \sigma_3.$$

Finalmente, el borde del triángulo relleno es

$$\partial\sigma_7 = \sigma_4 + \sigma_5 + \sigma_6.$$

En esta filtración, las primeras tres columnas son nulas, porque los vértices no tienen borde. Cada vértice crea inicialmente una componente conexa, es decir, una clase de H_0 . Al añadir las aristas σ_4 y σ_5 , algunas de esas componentes se fusionan, de modo que mueren clases de H_0 .

Al añadir la tercera arista σ_6 se completa el ciclo

$$\sigma_4 + \sigma_5 + \sigma_6,$$

y en ese paso aparece una nueva clase de H_1 que antes no existía. Finalmente, al añadir el triángulo relleno σ_7 , este ciclo pasa a ser borde:

$$\partial\sigma_7 = \sigma_4 + \sigma_5 + \sigma_6,$$

y la clase de H_1 muere.

El ejemplo permite ver como el algoritmo es capaz de detectar de forma algebraica la misma información geométrica: las aristas, al aparecer, pueden fusionar componentes (matando clases de H_0) o cerrar ciclos (creando clases de H_1), mientras que los triángulos rellenan ciclos previos y los hacen morir.

En el peor caso, el coste del algoritmo escala cúbicamente con el número de símlices. En la práctica esto se suele ver reducido ya que implementaciones más usadas en la literatura aplicada —**Ripser**, **GUDHI** o **giotto-tda**— emplean optimizaciones específicas que lo hacen más eficiente en conjuntos de datos reales.

4.5 Estabilidad

Lo que hace que la homología persistente sea útil más allá del marco teórico es que su resultado (los diagramas) no varía bruscamente cuando los datos se perturban un poco. Para dar formalmente esta idea de **estabilidad** se necesita primero una manera de medir distancias entre diagramas de persistencia.

Definición 4.9. Sean D_1 y D_2 dos diagramas de persistencia, considerados junto con la diagonal mencionada anteriormente (con multiplicidad infinita). La **distancia bottleneck** entre ellos es

$$d_B(D_1, D_2) = \inf_{\eta} \sup_{x \in D_1} \|x - \eta(x)\|_{\infty},$$

donde el ínfimo recorre todas las biyecciones $\eta : D_1 \rightarrow D_2$.

La interpretación de d_B es la siguiente: Tenemos que “mover” o “llevar” los puntos de D_1 a D_2 , d_B recoge cuánto debe desplazarse el punto que peor encaje, una vez que elegimos la asignación más favorable. Es, por tanto, una distancia ℓ^{∞} minimizada sobre todos los posibles emparejamientos.

La diagonal con multiplicidad infinita se incluye precisamente para que siempre exista una biyección: los puntos sin pareja natural pueden emparejarse con algún punto de la diagonal.

Por ejemplo, si una clase aparece en el diagrama como un punto (b, d) , su persistencia es $d - b$. La distancia de ese punto a la diagonal, en norma ∞ , es

$$\frac{d - b}{2}.$$

Por tanto, una barra corta está cerca de la diagonal y puede desaparecer con una perturbación pequeña, mientras que una barra larga está más alejada y requiere una perturbación mayor para ser eliminada.

Con la distancia bottleneck ya podemos enunciar el resultado que da nombre a esta sección. En el marco de este trabajo los diagramas de persistencia se obtienen de filtraciones de Vietoris–Rips de nubes de puntos finitas, así que la forma más útil del teorema de estabilidad es la que compara diagramas de dos nubes distintas. Recordemos que la **distancia de Hausdorff** entre dos subconjuntos finitos $X, Y \subseteq \mathbb{R}^d$ es

$$d_H(X, Y) = \max \left\{ \sup_{x \in X} \inf_{y \in Y} \|x - y\|, \sup_{y \in Y} \inf_{x \in X} \|x - y\| \right\},$$

es decir, el mayor desplazamiento necesario para llevar cada punto de una nube al más cercano de la otra.

Teorema 4.10 (Estabilidad de los diagramas de Vietoris–Rips). *Sean $X, Y \subseteq \mathbb{R}^d$ dos nubes finitas de puntos. Para cada dimensión p , los diagramas de persistencia de sus respectivas filtraciones de Vietoris–Rips satisfacen*

$$d_B(\text{Dgm}_p(\text{VR}(X)), \text{Dgm}_p(\text{VR}(Y))) \leq 2 d_H(X, Y).$$

Este resultado se sigue del teorema de estabilidad general de Cohen–Steiner, Edelsbrunner y Harer [3] aplicado a las funciones distancia asociadas a X e Y , y proporciona la garantía de robustez que necesitamos: si dos nubes están próximas en distancia de Hausdorff, sus diagramas de persistencia también lo están en distancia bottleneck. Esto quiere decir que, las características topológicas con persistencia grande son estables frente a perturbaciones pequeñas, mientras que las de baja persistencia pueden cambiar o desaparecer con más facilidad.

5 Análisis de series temporales mediante *sliding windows*

En este capítulo introducimos el método que conecta la homología persistente con el análisis de series temporales. Hasta ahora hemos trabajado con nubes de puntos en $\mathbb{R}^d$, pero en muchas aplicaciones los datos aparecen como una **serie temporal**, es decir, como una función

$$f : I \subseteq \mathbb{R} \longrightarrow \mathbb{R}$$

que registra la evolución de una magnitud a lo largo del tiempo. Lo que queremos plantear ahora es cómo podemos trasladar las herramientas de TDA, pensadas para nubes de puntos, a un objeto distinto como una serie temporal. La propuesta de Perea y Harer [9] da la respuesta en dos pasos: primero se convierte la serie en una nube de puntos mediante un *embedding por retardo* (que explicaremos posteriormente) y a esa nube se le aplica después la homología persistente que hemos descrito en los capítulos anteriores. El uso del embedding por retardo no es casual: proviene del estudio de sistemas dinámicos, antes de introducirlo formalmente, veremos en qué consiste y por qué permite recuperar información geométrica a partir de una única señal observada.

5.1 Series temporales y sistemas dinámicos

Las series temporales que aparecen en aplicaciones suelen ser, en realidad, observaciones parciales de un sistema dinámico subyacente. La evolución de ese sistema vive en un espacio de estados M ; si el sistema tiene k variables internas, M puede pensarse como un subconjunto de $\mathbb{R}^k$. En la práctica, sin embargo, no medimos todas esas variables, sino una sola magnitud escalar a lo largo del tiempo:

$$f(t) = \varphi(\Phi_t(p_0)),$$

donde $\Phi_t : M \rightarrow M$ describe la evolución temporal del sistema, $p_0 \in M$ es el estado inicial y $\varphi : M \rightarrow \mathbb{R}$ es la función de observación. Lo que nos preguntaremos, entonces, es si a partir únicamente de f podemos recuperar información sobre la dinámica que la genera.

El resultado clásico que justifica esta posibilidad es el Teorema de Takens [10].

Teorema 5.1 (Takens, 1981). *Sea M una variedad diferenciable compacta de dimensión d y sea $\Phi_t : M \rightarrow M$ un flujo suave. Para una observación escalar genérica $\varphi : M \rightarrow \mathbb{R}$ y un retardo $\tau > 0$ adecuado, la aplicación de retardos*

$$\Psi_{m,\tau} : M \longrightarrow \mathbb{R}^{m+1}, \quad p \longmapsto (\varphi(p), \varphi(\Phi_\tau(p)), \dots, \varphi(\Phi_{m\tau}(p))),$$

es un encaje para $m \geq 2d$.

Vamos a aclarar la convención de dimensiones del enunciado. El vector de retardos tiene $m + 1$ componentes, así que el espacio de llegada es $\mathbb{R}^{m+1}$ y no $\mathbb{R}^m$, y la condición $m \geq 2d$ equivale a $m + 1 \geq 2d + 1$. La cota $2d + 1$ se entiende por una cuenta de dimensiones: una variedad de dimensión d metida en $\mathbb{R}^n$ se autocorta cuando dos puntos distintos caen en el mismo lugar; el conjunto de pares de puntos distintos tiene dimensión $2d$ y la coincidencia impone n ecuaciones, de modo que para $n > 2d$ ese conjunto se espera vacío genéricamente. La imagen familiar es la de una curva ($d = 1$): en el plano puede cruzarse consigo misma, pero en $\mathbb{R}^3$ no. En la convención del teorema, por tanto, m es el número de retardos y no la dimensión del espacio ambiente.

Queremos entender ahora la idea de “encaje”, que $\Psi_{m,\tau}$ sea un encaje significa que la aplicación introduce M dentro de $\mathbb{R}^{m+1}$ sin colapsar (identificar) puntos distintos y respetando la estructura diferenciable del espacio original. De forma más intuitiva, los vectores de retardos van a permitir reconstruir una copia del espacio de estados que conservará su estructura geométrica esencial.

En la práctica, si tomamos varias observaciones retardadas de una misma señal: en t , $t + \tau$, $t + 2\tau$, etc; se obtiene una nube de puntos en $\mathbb{R}^{m+1}$ que contiene información sobre la dinámica subyacente. Si la dinámica es periódica, esa nube tenderá a organizarse alrededor de una curva cerrada; si es cuasiperiódica, puede aparecer una estructura toroidal; y en sistemas más complejos pueden surgir formas más irregulares. Aquí es donde entra TDA: los diagramas de persistencia de la nube reconstruida permiten detectar y cuantificar estas estructuras sin necesidad de visualizar el espacio de estados.

5.2 El embedding por ventanas deslizantes

Cuando partimos de una serie temporal escalar $f : I \rightarrow \mathbb{R}$, la traducción concreta del Teorema de Takens es la operación de **ventanas deslizantes**, que definimos a continuación.

Definición 5.2. *Dada una función continua $f : I \rightarrow \mathbb{R}$, un entero $M \geq 1$ y un retardo $\tau > 0$, definimos*

$$I_{M,\tau} = \{t \in I : t + M\tau \in I\}.$$

*El **embedding por ventana deslizante** con parámetros (M, τ) es la aplicación*

$$SW_{M,\tau}f : I_{M,\tau} \longrightarrow \mathbb{R}^{M+1},$$

dada por

$$SW_{M,\tau}f(t) = (f(t), f(t + \tau), f(t + 2\tau), \dots, f(t + M\tau)).$$

La dimensión de la reconstrucción es $M + 1$ y el parámetro τ es el que controla el retardo entre dos coordenadas consecutivas del vector $SW_{M,\tau}f(t)$. El producto

$$W = M\tau$$

se llama **tamaño de ventana** y juega un papel muy importante en lo que sigue. Si t recorre el intervalo $I_{M,\tau}$, la imagen $SW_{M,\tau}f(t)$ describe una curva continua en $\mathbb{R}^{M+1}$ que puede interpretarse como una trayectoria reconstruida de la serie. Al muestrear esta curva en un conjunto finito de tiempos

$$t_1 < t_2 < \dots < t_N,$$

obtenemos una nube de puntos a la que se le puede aplicar la filtración de Vietoris–Rips y calcular los diagramas de persistencia correspondientes.

La elección de M y τ no es inmediata. Aunque el Teorema de Takens 5.1 proporciona una cota teórica sobre M en función de la dimensión del espacio de estados, en datos reales esta dimensión no se conoce a priori, así que los parámetros suelen ajustarse de manera iterativa.

5.3 Geometría del caso periódico

Analicemos ahora uno de los casos más habituales de función con “periodicidad” (una puramente periódica como puede ser el coseno) y observemos como el embedding detecta la misma.

$$f(t) = \cos(Lt),$$

con $L > 0$ frecuencia angular. Aunque es un caso ideal, contiene la idea geométrica esencial: una señal periódica da lugar, vía ventanas deslizantes, a una nube con forma aproximadamente circular.

Aplicando la definición:

$$SW_{M,\tau}f(t) = (\cos(Lt), \cos(L(t + \tau)), \dots, \cos(L(t + M\tau))).$$

Usando la identidad trigonométrica

$$\cos(a + b) = \cos(a)\cos(b) - \sin(a)\sin(b),$$

cada coordenada puede escribirse como

$$\cos(L(t + k\tau)) = \cos(Lt)\cos(Lk\tau) - \sin(Lt)\sin(Lk\tau).$$

Por tanto,

$$SW_{M,\tau}f(t) = \cos(Lt)\mathbf{u} - \sin(Lt)\mathbf{v},$$

donde

$$\mathbf{u} = (\cos(Lk\tau))_{k=0}^M, \quad \mathbf{v} = (\sin(Lk\tau))_{k=0}^M.$$

Esta fórmula tiene una interpretación geométrica importante. Los vectores $\mathbf{u}$ y $\mathbf{v}$ no dependen de t : solo están determinados por los parámetros M y τ . Lo único que varía con el tiempo son los coeficientes

$$\cos(Lt) \quad \text{y} \quad \sin(Lt),$$

que recorren una circunferencia en el plano de coeficientes. Al combinarlos con $\mathbf{u}$ y $\mathbf{v}$, el resultado en $\mathbb{R}^{M+1}$ vive dentro del plano generado por ambos vectores y describe una elipse. Esto quiere decir que la periodicidad de f se traduce, después del embedding, en una curva cerrada: como la señal se repite con un período, los vectores de retardos también lo hacen, y la trayectoria reconstruida vuelve sobre sí misma.

El tamaño de ventana

$$W = M\tau$$

es el parámetro crítico para que esta curva sea geoméricamente útil. En [9] se demuestra que, para una señal sinusoidal pura, la elipse expuesta se aproxima a una circunferencia bien condicionada (curva estable ante pequeñas variaciones de los parámetros) y de radio máximo cuando W es próximo a un período de la señal, con la corrección discreta

$$W \approx \frac{M}{M+1} \cdot \frac{2\pi}{L}.$$

Esto es importante porque una nube de puntos repartida sobre una circunferencia genera una clase de homología en dimensión 1 con persistencia grande, mientras que si la curva está muy estirada o muy estrecha esa clase queda mucho más cerca de la diagonal del diagrama.

Para señales periódicas más generales, el mismo argumento se extiende mediante series de Fourier: cada armónico contribuye a un plano del embedding y la nube reconstruida vive en el subespacio suma. Las clases persistentes en H_1 correspondientes a los armónicos principales son las que se traducen, en la práctica, en barras largas del diagrama. De forma resumida: si una serie temporal es aproximadamente sinusoidal, sus ventanas deslizantes se organizan sobre una circunferencia y el diagrama Dgm_1 presenta un punto claramente alejado de la diagonal. Cuando la señal es irregular o no presenta repetición clara, esa clase dominante en H_1 deja de existir y el diagrama queda lleno únicamente de puntos cercanos a la diagonal.

Una señal periódica puede aproximarse por una suma finita de senos y cosenos,

$$S_N f(t) = \sum_{n=0}^N a_n \cos(nt) + b_n \sin(nt).$$

Cada armónico contribuye con una componente geométrica de tipo elíptico en el espacio de ventanas. Por tanto, el embedding de una señal periódica general puede entenderse como una combinación de las geometrías asociadas a sus frecuencias. La estabilidad de los diagramas de persistencia, vista en el Teorema 4.10, permite transferir esta interpretación desde las aproximaciones truncadas de Fourier a señales más generales [9].

5.4 El método SW1PerS

Lo que acabamos de ver sugiere una forma natural de cuantificar la periodicidad de una señal. Si una serie temporal presenta un comportamiento periódico, su nube de ventanas deslizantes debería mostrar una estructura aproximadamente circular; por tanto, al calcular homología persistente esperamos encontrar una clase destacada en dimensión 1. Esta es la idea central del método **SW1PerS** (*Sliding Windows and 1-dimensional Persistence Scoring*), introducido por Perea y Harer [9].

Definición 5.3. Dada una serie temporal f , parámetros M, τ y tiempos de muestreo $t_1, \dots, t_N$, consideramos la nube de ventanas

$$X_f = \{SW_{M,\tau} f(t_i)\}_{i=1}^N \subseteq \mathbb{R}^{M+1}.$$

El **score SW1PerS** de f se define como la mayor persistencia de una clase de homología en dimensión 1 del diagrama de Vietoris–Rips de X_f :

$$\text{SW1PerS}(f) = \max_{(b,d) \in \text{Dgm}_1(X_f)} (d - b).$$

En otras palabras, SW1PerS mide la longitud de la barra más larga en H_1 del código de barras asociado a la nube de ventanas. Una barra larga en dimensión 1 indica que la nube contiene un ciclo persistente, lo que se interpreta como evidencia de periodicidad en la señal original.

Ejemplo 5.4 (Interpretación del score SW1PerS). Supongamos que, al aplicar el embedding por ventanas deslizantes a una señal f , obtenemos una nube de puntos X_f cuyo diagrama de persistencia en dimensión 1 contiene los puntos

$$(0,15, 0,80), \quad (0,20, 0,27), \quad (0,35, 0,42).$$

Las persistencias correspondientes son

$$0,80 - 0,15 = 0,65, \quad 0,27 - 0,20 = 0,07, \quad 0,42 - 0,35 = 0,07.$$

Por tanto,

$$\text{SW1PerS}(f) = 0,65.$$

La interpretación es que hay una clase de H_1 mucho más persistente que las demás. Geométricamente, esto indica que la nube de ventanas tiene un ciclo dominante, es decir, una forma aproximadamente circular. En el contexto de series temporales, esta estructura circular se interpreta como evidencia de periodicidad en la señal original.

Para comparar señales de distinta amplitud o reconstrucciones en distintas dimensiones, suele normalizarse el score. En Perea y Harer [9], esta normalización se realiza dividiendo por una cota teórica asociada al caso ideal de una señal cosenoidal pura con los mismos parámetros. De este modo se obtiene un valor normalizado

$$\text{SW1PerS}_{\text{norm}}(f) \in [0, 1],$$

donde valores cercanos a 1 indican una estructura circular muy marcada en la nube de ventanas, y valores pequeños señalan que, para los parámetros elegidos, no se detecta una clase persistente dominante en dimensión 1.

La estabilidad del método se apoya en dos hechos. Por un lado, la homología persistente es estable frente a perturbaciones de los datos, como vimos en el Teorema 4.10. Por otro lado, el operador de ventanas deslizantes es Lipschitz respecto a la norma del supremo de la señal. En particular, Perea y Harer prueban que

$$\|SW_{M,\tau}f - SW_{M,\tau}g\|_{\infty} \leq \sqrt{M+1} \|f - g\|_{\infty}.$$

Combinando esta desigualdad con la estabilidad de los diagramas de persistencia se obtiene una cota explícita para la variación del score SW1PerS bajo perturbaciones de la señal.

Una de las aplicaciones destacadas del método es la detección de genes con expresión periódica en datos de microarrays del ciclo celular. En este contexto, SW1PerS resulta especialmente útil porque no exige que la señal tenga una forma cosenoidal pura: lo que detecta es la presencia de una estructura circular persistente en la nube de ventanas, y no únicamente la correlación con una onda sinusoidal concreta [9].

Con esto queda cerrado el marco teórico necesario para el trabajo. El recorrido seguido en estos capítulos ha ido de la motivación general del TDA a la construcción algebraica de la homología, de ahí a su versión persistente mediante filtraciones y códigos de barras, y por último al método de ventanas deslizantes que conecta todo ese aparato con el análisis de series temporales. La parte siguiente del trabajo se ocupa de la implementación computacional, los experimentos numéricos y la interpretación de los resultados.

6 Detección de cambios en series temporales mediante diagramas de persistencia

En el capítulo anterior vimos cómo el embedding por ventana deslizante transforma una serie temporal en una nube de puntos, y cómo la homología persistente de esa nube permite detectar periodicidad en la señal. Sin embargo, ese análisis es global: se calcula un único diagrama de persistencia a partir de toda la serie, y lo que se mide es una propiedad del conjunto completo.

Lo que queda sin responder con este enfoque es cuándo cambia la dinámica durante el intervalo de observación: $\text{SW1PerS}(f)$ va a devolver un único valor para toda la serie, así que señales que tengan una parte periódica seguida de una parte aleatoria pueden recibir calificaciones muy parecidas a las de una señal globalmente periódica más débil. Para distinguir esos casos hace falta un análisis más localizado.

En este capítulo vamos a seguir esta idea. En lugar de procesar la serie entera de una sola vez, recorreremos la serie con una ventana móvil, aplicamos el embedding por retardo dentro de cada ventana y construimos así una secuencia de diagramas de persistencia (uno por cada posición de la ventana). Si la señal cambia de régimen en algún instante interno, las nubes calculadas a ambos lados de ese instante deberían producir diagramas distintos, y esa diferencia podrá cuantificarse mediante una distancia entre diagramas.

6.1 Del análisis global al análisis local

El método SW1PerS , tal como lo introdujimos en la Sección 5.4, aplica el embedding $\text{SW}_{M,\tau}f$ a todos los instantes disponibles de la serie y genera una única nube global $X_f \subseteq \mathbb{R}^{M+1}$. Su diagrama de persistencia resume la estructura topológica de la señal vista en su conjunto: un valor alto de $\text{SW1PerS}(f)$ indica periodicidad global para los parámetros elegidos, mientras que valores pequeños nos indicarán ausencia de la misma. Pero el método no responde a la pregunta de si la señal cambia a lo largo del tiempo.

Para abordar esa pregunta, la modificación natural es la siguiente: en lugar de una sola ventana que abarca toda la serie, tomamos ventanas locales de longitud fija y las desplazamos a lo largo del tiempo. A cada posición de la ventana le corresponde un fragmento de la serie, sobre el que aplicamos el embedding de retardos para obtener la nube local y su diagrama de persistencia. El resultado es una secuencia de diagramas, uno por cada posición, que describe cómo evoluciona la estructura topológica local a lo largo del tiempo.

La diferencia con el capítulo anterior es la siguiente. En el Capítulo 5 el embedding producía vectores de la forma

$$\text{SW}_{M,\tau}f(t) = (f(t), f(t + \tau), \dots, f(t + M\tau)),$$

y todos esos vectores se reunían en una sola nube. Aquí, cada ventana local produce su propio conjunto de vectores, que forman su propia nube y dan lugar a su propio diagrama. Comparar diagramas de ventanas consecutivas permite detectar los instantes en que la estructura topológica cambia de forma brusca, lo que se interpreta como un cambio en la dinámica subyacente de la serie.

6.2 Construcción de la secuencia de diagramas

Sea $\mathbf{x} = (x_1, x_2, \dots, x_T)$ una serie temporal discreta de longitud T . Fijamos una longitud de ventana local $n < T$, que determina cuántos puntos se incluyen en cada análisis, y un paso $s \geq 1$, que indica cuántos puntos se avanza la ventana en cada iteración.

Para cada índice $k = 0, 1, \dots, K-1$, donde $K = \lfloor (T-n)/s \rfloor + 1$, definimos el segmento local

$$\mathbf{x}^{(k)} = (x_{1+ks}, x_{2+ks}, \dots, x_{n+ks}).$$

A este segmento le aplicamos el embedding por ventana deslizante con parámetros M y τ (Definición 5.2). Como el segmento local tiene longitud n y el embedding requiere que el índice más adelantado $j + M\tau$ esté dentro del segmento, el rango admisible para j es $j = 1, 2, \dots, n - M\tau$. La nube local queda entonces definida como

$$X^{(k)} = \{ SW_{M,\tau} \mathbf{x}^{(k)}(j) : 1 \leq j \leq n - M\tau \} \subseteq \mathbb{R}^{M+1},$$

que está formada por $n - M\tau$ vectores de retardos en $\mathbb{R}^{M+1}$. Implícitamente suponemos que $n > M\tau$, lo cual es siempre el caso en los parámetros que se utilizan en los capítulos prácticos.

Sobre esta nube calculamos la filtración de Vietoris–Rips y extraemos el diagrama de persistencia en dimensión 1:

$$D^{(k)} = \text{Dgm}_1(X^{(k)}).$$

Repitiendo este proceso para cada k obtenemos la secuencia $D^{(0)}, D^{(1)}, \dots, D^{(K-1)}$, en la que cada diagrama describe la estructura topológica local de la señal en el intervalo cubierto por la k -ésima ventana.

Ejemplo 6.1 (Secuencia de diagramas en una señal con cambio). *Consideremos una serie sintética de longitud $T = 500$, compuesta por una primera mitad periódica y una segunda mitad de ruido gaussiano. Fijamos $n = 80$, $s = 5$, $M = 10$ y $\tau = 3$.*

Para las primeras posiciones de la ventana, la nube local $X^{(k)}$ se construye a partir de puntos del tramo periódico. Por ello, presenta una estructura aproximadamente circular, que se refleja en el diagrama $D^{(k)}$ mediante una barra persistente en H_1 .

A medida que la ventana incorpora observaciones del tramo ruidoso, dicha estructura deja de ser visible. La barra principal en H_1 se acorta y, cuando la ventana queda situada completamente en la parte aleatoria, los puntos del diagrama se concentran cerca de la diagonal. Esta transición en los diagramas indica el cambio de régimen de la señal.

6.3 Parámetros del método

El método involucra cinco parámetros cuya elección condiciona la calidad del análisis y la sensibilidad de la detección.

La longitud de ventana local n determina cuántos puntos de la serie participan en cada nube. Ventanas largas capturan mejor las estructuras de baja frecuencia, pero tienen menor resolución temporal y pueden mezclar regímenes distintos si el cambio ocurre dentro

de la ventana. Ventanas cortas reaccionan antes a los cambios, aunque con pocos puntos los diagramas resultan menos fiables. En la práctica conviene que n sea lo suficientemente grande como para que la nube local contenga varios periodos de la señal, en coherencia con la condición de tamaño de ventana discutida en el Capítulo 5.

El paso s determina con qué frecuencia se avanza la ventana y, por tanto, cuántos diagramas se calculan. Con $s = 1$ se obtiene la máxima resolución temporal, a costa de calcular cerca de T diagramas; valores mayores reducen el coste computacional con una resolución más gruesa. Cabe notar que el solapamiento entre ventanas consecutivas es $n - s$: cuando el paso es mucho menor que n , las ventanas comparten la mayor parte de sus datos y los diagramas cambian lentamente, lo que puede suavizar la señal de distancias.

Los parámetros dimensión de embedding M y retardo τ son los mismos que aparecen en la Definición 5.2 y se aplican de forma idéntica dentro de cada ventana local. Su elección condiciona la geometría de la nube de puntos y, con ella, la capacidad del diagrama para reflejar la periodicidad de la señal. Para orientar la elección de τ puede usarse la autocorrelación de la serie, tal como se discute en [9]. No existe una elección óptima universal: en la práctica se combinan el criterio teórico de Perea y Harer sobre el tamaño de ventana $W = M\tau$ con una exploración empírica sobre los datos concretos, como se ilustra en el Capítulo 7.

6.4 Comparación de diagramas consecutivos

Una vez que hemos obtenido la secuencia $D^{(0)}, \dots, D^{(K-1)}$, el siguiente paso es cuantificar cómo cambia de un diagrama al siguiente. Para ello recurrimos a la *distancia bottleneck* d_B introducida en la Definición 4.9, que ya quedó motivada y discutida en el Capítulo 4.

La elección de d_B en este contexto se apoya en el Teorema de estabilidad 4.10: si dos funciones de filtración difieren poco en norma uniforme, sus diagramas también lo hacen en distancia bottleneck. Si lo trasladamos a nuestro caso, esta propiedad garantiza que pequeñas perturbaciones de la serie producen variaciones acotadas en los δ_k , y que por tanto los picos de la señal (δ_k) captan cambios reales de la estructura local y no efectos de ruido.

Aplicada a la secuencia de diagramas, calculamos para cada par

$$\delta_k = d_B(D^{(k)}, D^{(k+1)}), \quad k = 0, \dots, K-2,$$

obteniendo la señal de distancias $(\delta_0, \delta_1, \dots, \delta_{K-2})$. Esta señal registra, en cada paso, cuánto varía la estructura topológica local de la serie: cuando la geometría de las ventanas es estable los valores serán pequeños, en caso contrario la distancia aumentará indicando un cambio en la señal.

6.5 Criterio de detección basado en un umbral

La señal de distancias (δ_k) puede analizarse visualmente para identificar picos, pero para automatizar la detección es necesario definir un criterio explícito. El más directo consiste en fijar un umbral $\delta^* > 0$ y declarar un cambio en la posición k^* si

$$\delta_{k^*} > \delta^*.$$

La cuestión práctica es cómo elegir δ^* de forma justificada. Una primera aproximación es la inspección visual: al representar la señal de distancias suele resultar evidente si hay

picos aislados y claramente destacados sobre el resto, lo que da una idea rápida de si el método está capturando algo significativo, aunque no es sistemático.

Cuando se dispone de un tramo inicial sin cambios esperados, resulta más riguroso estimar la media μ y la desviación típica σ de las distancias en ese tramo de referencia y fijar

$$\delta^* = \mu + c \sigma,$$

donde c controla la sensibilidad, típicamente entre 2 y 3. Un valor de δ_k que supere ese umbral se interpreta como estadísticamente atípico respecto del comportamiento en régimen estacionario.

La opción más sistemática, y la que se adoptará en el Capítulo 7, es la calibración con señales sintéticas: se generan series con cambios en posiciones conocidas, se aplica el método y se observa qué valores de δ^* permiten detectar esos cambios sin producir demasiadas falsas alarmas.

En cualquier caso, el índice k^* donde se detecta el cambio corresponde a la posición de la ventana en la señal de distancias, no necesariamente a un instante exacto de la serie original. Localizar el cambio con mayor precisión dentro del intervalo cubierto por esa ventana requeriría un análisis más fino que queda fuera del alcance de este trabajo.

En los capítulos siguientes ponemos el procedimiento a prueba: primero sobre señales sintéticas con cambios conocidos (Capítulo 7) y después sobre una serie financiera real (Capítulo 8), donde también se discutirán en detalle las limitaciones que surgen al aplicarlo.

7 Experimentos con datos sintéticos

En los capítulos anteriores se ha construido el marco teórico necesario para aplicar la homología persistente al análisis de series temporales. En el Capítulo 5 se introdujeron el embedding por ventanas deslizantes y el score SW1PerS, mientras que en el Capítulo 6 se explicó cómo adaptar estas ideas a un análisis local mediante una sucesión de diagramas de persistencia. En este capítulo se estudia el comportamiento del método sobre señales sintéticas. La ventaja de trabajar con este tipo de datos es que la estructura de la señal se conoce de antemano, lo que permite comprobar de manera controlada si el procedimiento detecta los cambios esperados. El código completo utilizado en este capítulo y en el siguiente está disponible en el repositorio público <https://github.com/gtarjuelo/tda-series-temporales>

7.1 Señales sintéticas de partida

Trabajamos con cuatro tipos de señal de longitud $T = 600$. La primera es una cosenoidal pura,

$$f(t) = \cos\left(\frac{2\pi t}{40}\right),$$

que se utiliza como caso de referencia con periodicidad exacta. Sobre esa cosenoidal añadimos ruido gaussiano $\eta(t) \sim \mathcal{N}(0, \sigma^2)$ para valores crecientes de σ , con la idea de estudiar cómo se degrada la información topológica al ensuciar la señal. También probamos con ruido blanco puro, sin estructura temporal. Por último consideramos una señal cuasi-periódica, suma de dos cosenoidales con períodos 40 y 70. La Figura 7.1 muestra las cuatro señales representadas en el mismo eje temporal.




Figura 7.1: Las cuatro señales sintéticas que servirán de banco de pruebas en este capítulo.

7.2 Embedding y diagramas

A cada una de estas señales le aplicamos el embedding $\text{SW}_{M,\tau}f$ definido en la Sección 5.2, con $M = 8$ y $\tau = 4$. Obtenemos una nube de puntos en $\mathbb{R}^9$ que no podemos visualizar pero sí calcular su diagrama de persistencia.

La Figura 7.2 muestra el resultado para la cosenoidal pura: la nube proyectada describe un anillo limpio y el diagrama de H_1 presenta un punto muy alejado de la diagonal, indicio de un agujero unidimensional persistente. Las figuras 7.3 y 7.4 ilustran cómo esa estructura se degrada al introducir ruido y desaparece por completo en el caso del ruido blanco. En la Figura 7.5 la suma de dos cosenoidales produce una nube con dos lazos, reflejados en el diagrama como dos puntos persistentes en H_1 .




Figura 7.2: Cosenoidal pura. La nube se cierra en un anillo y el diagrama de H_1 tiene un único punto destacado.




Figura 7.3: Cosenoidal contaminada con ruido moderado. La estructura circular sigue siendo reconocible pero el punto del diagrama se acerca a la diagonal.




Figura 7.4: Ruido blanco. No hay estructura circular y los puntos del diagrama se agrupan junto a la diagonal.




Figura 7.5: Suma de dos cosenoidales. Aparecen dos puntos persistentes en H_1 , uno por cada frecuencia dominante.

7.3 Score SW1PerS y robustez frente al ruido

Los resultados anteriores son cualitativos. Para resumirlos en un único número utilizamos el score SW1PerS de la Sección 5.4, que consiste en dividir la persistencia máxima en H_1 por una cota teórica de referencia.

La cota que empleamos, $2 \sin(\pi/(M+2))$, tiene un origen geométrico. Cuando el tamaño de ventana coincide con un período de la señal, los $M+1$ vectores de la nube SW se distribuyen aproximadamente sobre un polígono regular inscrito en una circunferencia. La persistencia máxima en H_1 del complejo de Vietoris–Rips de un polígono regular de N vértices inscrito en una circunferencia unidad vale $2 \sin(\pi/N)$, esta es la escala a la que el polígono queda relleno por triángulos y el ciclo dominante muere. En nuestro caso $N = M+1$ vértices, corregido por el factor discreto que aparece en el tamaño óptimo de ventana $W = M\tau$, lleva a la expresión $2 \sin(\pi/(M+2))$.

En [9] Perea y Harer usan una normalización algo distinta, basada en la cota $\sqrt{3}$ correspondiente al caso continuo de una circunferencia unidad. Con su elección el score queda por construcción en $[0, 1]$. En este trabajo utilizamos la cota discreta $2 \sin(\pi/(M+2))$, que depende de M por lo que no hay una acotación estricta. Para señales cosenoidales puras con parámetros muy próximos al óptimo el cociente puede superar uno, algo que se observa en la figura 7.6. La interpretación será la misma, valores cercanos a la cota indican estructura circular y valores pequeños ausencia de periodicidad.

Sobre las seis señales del banco de pruebas obtenemos los valores de la figura 7.6: la cosenoidal pura, la cosenoidal contaminada con ruido gaussiano de tres niveles crecientes $\sigma \in \{0, 1, 0, 3, 0, 6\}$, el ruido blanco y la suma de dos cosenoidales. La cosenoidal pura queda cerca de uno (con ligero exceso por la razón discreta comentada), la introducción de ruido baja el score de forma gradual y el ruido blanco se queda en un valor pequeño, próximo al de las señales sin estructura.




Figura 7.6: Score SW1PerS normalizado para varias señales sintéticas con $M = 8$, $\tau = 3$.

Para profundizar un poco más en la robustez del método, en la Figura 7.7 se representa la persistencia máxima en H_1 frente a la desviación típica del ruido aditivo σ , recorriendo $\sigma \in [0, 1,5]$. La curva no presenta cambios abruptos, lo cual es la traducción experimental del Teorema de estabilidad 4.10.




Figura 7.7: Persistencia máxima H_1 frente al nivel de ruido σ . La degradación es continua, en línea con la estabilidad teórica del diagrama.

7.4 Influencia de los parámetros del embedding

El éxito del método depende de la elección de M y τ , como ya señalamos en el Capítulo 5. Para visualizar esa dependencia hemos hecho un barrido sobre una cosenoidal de período 40, midiendo el score SW1PerS para cada combinación. El resultado está en la Figura 7.8. Los valores altos del score se concentran en torno a $W = M\tau \approx 30$, que es lo que predice la teoría: la ventana óptima tiene tamaño próximo al período de la señal, ligeramente reducido por el factor $M/(M+1)$. Valores demasiado pequeños de W no cierran un ciclo; valores demasiado grandes superponen varios y ocultan la geometría circular.




Figura 7.8: Score SW1PerS en función de M y τ sobre una cosenoidal de período 40.

7.5 Detección de cambios sobre series sintéticas

Las secciones anteriores comprueban el método sobre señales fijas. La pregunta que queremos resolver es otra; si la dinámica de la serie cambia en algún momento, ¿somos

capaces de identificar cuándo? Para responderla construimos tres casos en los que el instante del cambio es conocido y comparamos la posición predicha por el detector con la posición real.

En los tres experimentos la serie tiene longitud $T = 500$, el cambio se produce en $t = 250$ y se aplica el procedimiento del Capítulo 6 con ventana local $n = 80$, paso $s = 5$, embedding $M = 10$ y retardo $\tau = 3$. Las distancias entre diagramas consecutivos se calculan con la distancia bottleneck.

Para automatizar la decisión sobre cuándo se produce el cambio utilizamos un criterio basado en estimadores robustos. En lugar del clásico $\mu + 3\sigma$, fijamos el umbral en $\text{mediana}(S_{\text{ref}}) + 4 \cdot \text{MAD}(S_{\text{ref}})$, donde S_{ref} es el primer tramo de la señal de distancias y MAD es la desviación absoluta mediana reescalada por el factor estándar 1,4826. La mediana y la MAD no se contaminan por valores extremos del tramo de referencia, cosa que sí ocurre con μ y σ cuando ese tramo es corto. Además exigimos dos cruces consecutivos del umbral antes de declarar la detección, para filtrar picos aislados de ruido. Esta implementación es la del módulo `codigo/detector.py`.

7.5.1 Experimento 1: de señal periódica a ruido

La serie es periódica en su primera mitad, una cosenoidal de período 40, y se convierte en ruido gaussiano de varianza moderada a partir de $t = 250$. Al pasear la ventana por el tramo periódico los diagramas se parecen entre sí y la distancia bottleneck es pequeña; cuando la ventana entra en el tramo ruidoso la geometría se pierde y aparece un pico bien marcado. La serie y la señal de distancias se representan en la figura 7.9, y las nubes SW antes y después del cambio en la figura 7.10.




Figura 7.9: Experimento 1. Serie sintética (izquierda) y distancia bottleneck entre diagramas consecutivos (derecha) con el umbral robusto y la fecha de cambio marcadas.




Figura 7.10: Experimento 1. Nubes SW proyectadas a 2D antes (izquierda) y después (derecha) del cambio. La estructura circular se desvanece al entrar en el régimen de ruido.

7.5.2 Experimento 2: cambio de frecuencia

Aquí la serie es periódica tanto antes como después del cambio, pero la frecuencia pasa de período 40 a período 70. Ambas mitades producen una nube aproximadamente circular, así que la distancia entre diagramas no se dispara por la desaparición del ciclo sino por la deformación de su geometría. La serie y la señal de distancias se representan en la figura 7.11, y las nubes SW antes y después del cambio en la figura 7.12.




Figura 7.11: Experimento 2. El pico de la curva de distancias es algo más bajo que en el primer experimento, pero suficientemente claro para superar el umbral robusto.




Figura 7.12: Experimento 2. Las dos nubes son circulares pero el cambio de período se traduce en un cambio en el tamaño y la orientación del lazo dentro del plano principal.

7.5.3 Experimento 3: de ruido a señal periódica

El tercer experimento es la inversa del primero. La serie empieza siendo ruido y a partir de $t = 250$ aparece una cosenoidal de período 40. Lo que comprobamos aquí es que el método no se limita a detectar la desaparición de estructura: también responde cuando esta aparece. La serie y la señal de distancias se representan en la figura 7.13, y las nubes SW antes y después del cambio en la figura 7.14.




Figura 7.13: Experimento 3. La distancia bottleneck reacciona en cuanto la ventana empieza a contener la señal periódica.




Figura 7.14: Experimento 3. La nube SW pasa de no tener estructura apreciable (izquierda) a cerrarse en un anillo (derecha) en cuanto la ventana entra completamente en el tramo periódico.

7.5.4 Interpretación conjunta

Los tres experimentos confirman tres afirmaciones sobre el método. La primera es que en regímenes estacionarios los diagramas consecutivos se parecen entre sí y la señal de distancias se mantiene pequeña. La segunda es que un cambio brusco en la dinámica produce un pico que puede aislarse con el detector robusto. La tercera, quizá la más interesante, es que la respuesta del método es simétrica: detecta tanto la desaparición de estructura como su aparición.

En los tres experimentos la fecha detectada queda algunas decenas de muestras por delante del instante real del cambio. Esto es una consecuencia geométrica del análisis por ventanas. La ventana de longitud $n = 80$ empieza a contener observaciones del nuevo régimen mucho antes de que su centro lo cruce, y el diagrama de esa ventana ya se deforma con esa mezcla parcial. La detección refleja, por tanto, el primer momento en que aparece la contaminación; la resolución temporal del método queda acotada por n y por el paso s elegidos.

7.6 Conclusión del capítulo

El capítulo ha verificado que el embedding por ventanas deslizantes traducido al lenguaje de la homología persistente recupera información geométrica útil sobre la serie original, las señales periódicas se manifiestan como ciclos en H_1 y el score SW1PerS las identifica de forma cuantitativa. El procedimiento local del Capítulo 6 es capaz de localizar los instantes en que la dinámica cambia, dentro de un margen acotado por la longitud de la ventana. En el capítulo siguiente aplicamos el método a una serie financiera real.

8 Aplicación a una serie financiera real

En el capítulo anterior se validó el método sobre series sintéticas en las que conocíamos el instante exacto del cambio de régimen. Ahora aplicamos el mismo procedimiento a datos reales. La serie elegida es el índice S&P 500 alrededor de la crisis financiera de 2008, uno de los episodios mejor documentados de la historia bursátil reciente.

Este caso se ha escogido porque reúne varias condiciones útiles para el análisis. Por un lado, la quiebra de Lehman Brothers, el 15 de septiembre de 2008, proporciona una fecha de referencia clara con la que comparar los resultados. Además, el comportamiento del índice cambia de forma visible en torno a ese periodo, por lo que tiene sentido estudiar si el método detecta una variación en la estructura de la serie. Por último, los datos diarios del S&P 500 están disponibles públicamente, lo que facilita que el experimento pueda reproducirse.

8.1 Datos y preprocesado

Trabajamos con las cotizaciones de cierre diarias del S&P 500 entre el 1 de enero de 2008 y el 30 de junio de 2009, descargadas con la librería `yfinance`. La elección del intervalo busca un compromiso: el tramo previo a septiembre debe ser suficientemente largo para estimar de forma estable el comportamiento en régimen normal, y el tramo posterior debe cubrir el desplome agudo de septiembre y octubre, los mínimos de marzo de 2009 y las primeras semanas de recuperación posterior. De este modo el análisis abarca el ciclo completo de la crisis, desde el régimen previo hasta la vuelta a un comportamiento más estable.

Los precios diarios no son la opción más adecuada para aplicar el método directamente. La razón es que la serie de precios no suele ser estacionaria y, además, su escala cambia con el tiempo. Por ello, en lugar de trabajar con los precios, se consideran los retornos logarítmicos diarios,

$$r_t = \log p_t - \log p_{t-1},$$

donde p_t es el precio de cierre del día t . Estos retornos son aproximadamente estacionarios en régimen estable y recogen la información relevante sobre el cambio relativo del índice. Antes de aplicar el embedding, además, estandarizamos restando la media y dividiendo por la desviación típica, de manera que el orden de magnitud de las distancias bottleneck sea comparable. La Figura 8.1 muestra el resultado del preprocesado: arriba el nivel del índice y abajo los retornos diarios, en los que se distingue con claridad el cambio de régimen en volatilidad a partir de septiembre.




Figura 8.1: S&P 500 entre enero de 2008 y junio de 2009. Arriba, el nivel de cierre; abajo, los retornos logarítmicos diarios. La línea discontinua marca el 15 de septiembre de 2008.

8.2 Aplicación del método

Aplicamos a la serie de retornos estandarizados el procedimiento del Capítulo 6. Tomamos ventana local $n = 80$ días hábiles, lo que equivale aproximadamente a un trimestre bursátil, y paso $s = 10$. La dimensión de embedding es $M = 4$ y el retardo $\tau = 3$. Estos dos últimos parámetros son menores que los utilizados con las señales sintéticas del capítulo anterior. En una serie de retornos no se busca detectar una periodicidad clara, sino comparar cambios en la geometría local de las nubes de puntos. Por eso conviene trabajar con dimensiones moderadas, evitando que la información quede demasiado dispersa en el espacio de embedding.

Para cada posición de la ventana construimos la nube $X^{(k)}$ con los retardos del segmento local, le calculamos su diagrama $\text{Dgm}_1^{(k)}$, y formamos la señal de distancias $\delta_k = d_B(\text{Dgm}_1^{(k)}, \text{Dgm}_1^{(k+1)})$. Sobre esta señal aplicamos el detector robusto presentado en la Sección 7.5: umbral en mediana + $4 \cdot \text{MAD}$ estimado sobre el primer tramo, y exigencia de dos cruces consecutivos para confirmar la detección.

8.3 Resultado del análisis

La Figura 8.2 muestra la señal de distancias a lo largo del tiempo, junto con el umbral y la fecha histórica del crash. El primer cruce confirmado se produce en una ventana cuyo inicio está a comienzos de agosto de 2008, unas seis semanas antes de la quiebra de Lehman. Esta detección anticipada es coherente con la interpretación financiera del periodo: desde la primavera de 2008 las tensiones de liquidez se manifestaban en episodios como la quiebra de Bear Stearns en marzo, y los retornos diarios mostraban una volatilidad creciente que aún no llegaba a los niveles del otoño pero que ya rompía con el patrón del año anterior. El método no detecta el día de Lehman porque el régimen de alta volatilidad no empezó ahí, sino que se intensificó. Lo que captura es el primer instante en el que la geometría local de los retornos deja de parecerse a la del régimen previo.




Figura 8.2: Distancia bottleneck entre diagramas consecutivos. La línea discontinua roja indica el umbral robusto. La línea verde marca la quiebra de Lehman; la naranja, la primera detección.

Para visualizar qué traduce el método al nivel de los diagramas, la Figura 8.3 compara dos de ellos. El primero corresponde a una ventana del régimen previo y presenta los puntos típicos del análisis de retornos en periodos tranquilos: distribución concentrada cerca de la diagonal y sin clase claramente dominante. El segundo, ya en el régimen de crisis, muestra puntos desplazados hacia escalas mayores y con más dispersión, lo que indica una nube local con estructura geométrica menos compacta.




Figura 8.3: Diagramas de persistencia H_1 correspondientes a una ventana del régimen previo (izquierda) y a una ventana posterior a la detección (derecha).

8.4 Validación sobre otros episodios históricos

Una sola detección no permite afirmar que el método sea robusto. Vamos a aplicar el mismo procedimiento a otros cinco episodios bursátiles conocidos. El crash de Wall Street de octubre de 1929, el Lunes Negro del 19 de octubre de 1987, el pinchazo de la burbuja punto-com con pico el 24 de marzo de 2000, el crash de la pandemia de COVID-19 marcado por el primer *circuit breaker* del 9 de marzo de 2020 y el inicio del mercado bajista de 2022 a partir del pico del S&P 500 del 4 de enero. Los datos diarios reales se han descargado con `yfinance`. Los parámetros del método son los mismos que en el análisis del crash de 2008 en lo que respecta al embedding ($M = 4$, $\tau = 3$), pero la ventana local y el paso se han reducido ligeramente a $n = 60$ y $s = 8$. Este ajuste es práctico, dado que las series de los eventos más antiguos son sensiblemente más cortas que las modernas, y una ventana algo más pequeña asegura que todos los episodios produzcan suficientes diagramas consecutivos para construir una señal de distancias significativa. Como consecuencia, la fecha detectada para el crash de 2008 en este análisis multi-evento puede diferir en unos pocos días respecto a la del análisis detallado de la sección anterior;

ambas cifras son igualmente válidas y solo reflejan la sensibilidad del método a la elección concreta de n y s .

Los resultados se recogen en la Tabla 8.1.

Tabla 8.1: Detecciones automáticas sobre seis episodios históricos. El campo Δ es la diferencia en días entre la fecha detectada y la fecha de referencia (negativo indica detección anticipada).

Evento	Referencia	Detectado	Δ
Crash de 1929	1929-10-29	1929-09-03	−56
Lunes Negro 1987	1987-10-19	1987-08-10	−70
Burbuja punto-com 2000	2000-03-24	2001-01-23	+305
Crisis financiera 2008	2008-09-15	2008-07-29	−48
Crash COVID-19 2020	2020-03-09	2020-02-25	−13
Mercado bajista 2022	2022-01-04	2021-12-23	−12

En cinco de los seis casos la detección se anticipa al evento de referencia con un margen que va de las dos a las diez semanas. En crashes muy abruptos, como el COVID o el inicio del mercado bajista de 2022, la anticipación es de pocos días: cuando una transición es casi instantánea, no hay margen para detectarla mucho antes. En episodios donde el deterioro se produce de forma más gradual, como en 1929 o en 2008, la detección aparece con un margen de uno o dos meses respecto al evento de referencia. Esto es razonable, ya que en estos casos el aumento de la volatilidad no se concentra en un único día, sino que se va acumulando durante las semanas previas.

El caso del pinchazo de la burbuja punto-com es la excepción que conviene comentar. La detección ocurre 305 días después del pico del 24 de marzo de 2000, en enero de 2001. No parece tanto un fallo del método como una consecuencia del tipo de episodio analizado. La burbuja punto-com no dio lugar a una caída brusca concentrada en pocos días, sino a un descenso prolongado durante casi dos años. En ese contexto, la volatilidad local del índice fue aumentando de manera gradual, y por eso el detector se mantiene por debajo del umbral durante buena parte del proceso. La señal solo supera la frontera robusta cuando, a comienzos de 2001, la serie entra en un régimen de volatilidad más claramente diferenciado. Esto sugiere que el procedimiento funciona mejor ante cambios relativamente rápidos en la geometría local de la serie, pero tiene más dificultades para detectar transiciones lentas y sostenidas. Los seis casos se representan de forma comparativa en la figura 8.4, donde puede apreciarse a la vez la señal de distancias, el umbral robusto y la fecha de referencia de cada evento.

8.5 Comparación con un detector clásico

Para situar el aporte del método, conviene compararlo con un detector clásico de cambios de régimen. La opción más natural es la *varianza móvil* de los retornos. Para cada ventana calculamos $\hat{\sigma}_k^2$ y aplicamos el mismo detector robusto, con los mismos hiperparámetros, sobre esa señal. Con esta elección, los dos métodos se comparan bajo el mismo criterio de decisión. Por tanto, si aparecen diferencias en las fechas señaladas, estas vienen del tipo de información que mide cada descriptor y no de haber usado umbrales distintos. Los resultados se recogen en la Tabla 8.2.




Figura 8.4: Señal de distancia bottleneck para los seis episodios. Línea verde de puntos: fecha de referencia. Línea naranja discontinua: primera detección. Línea roja discontinua: umbral robusto.

Tabla 8.2: Comparación de las detecciones con el mismo detector aplicado a la señal topológica d_B y a la varianza móvil clásica. Última columna: diferencia $\Delta_{TDA} - \Delta_{Var}$ (positivo: la varianza se adelanta a la TDA).

Evento	Referencia	TDA	Var.	$\Delta_T - \Delta_V$
Crash de 1929	1929-10-29	-56	-91	+35
Lunes Negro 1987	1987-10-19	-70	-82	+12
Burbuja punto-com 2000	2000-03-24	+305	-92	+397
Crisis financiera 2008	2008-09-15	-48	-70	+22
Crash COVID-19 2020	2020-03-09	-13	-13	0
Mercado bajista 2022	2022-01-04	-12	-34	+22

La interpretación requiere algo de cuidado. En el caso del crash COVID, ambas señales detectan el cambio el mismo día, lo que tiene sentido porque se trata de una transición muy brusca. En el resto de episodios, la varianza móvil suele adelantarse a la señal topológica entre dos semanas y un mes.

Este adelanto, sin embargo, no implica necesariamente que la varianza sea mejor. Al trabajar con ventanas relativamente cortas, la varianza móvil puede oscilar bastante y generar más falsas alarmas en periodos estacionarios. La señal topológica parece más estable en ese sentido, porque no depende de un único estadístico, sino de la forma de la nube de puntos asociada a cada ventana. A cambio, esa mayor selectividad puede hacer que tarde más en reaccionar cuando el cambio de régimen es gradual.

Ninguno de los dos descriptores es estrictamente superior. La conclusión interesante de cara al trabajo futuro es la complementariedad. Un esquema híbrido que utilice la varianza como aviso temprano y la TDA como filtro de confirmación podría reducir la tasa de falsos positivos sin perder reactividad, e incluso resolver el caso problemático de

las transiciones suaves. Esta línea se retoma en el capítulo de conclusiones.

8.6 Limitaciones y cierre del capítulo

Antes de cerrar el capítulo conviene reconocer los puntos débiles que el experimento ha dejado a la vista. Algunos son propios del método; otros se han hecho visibles solo al trabajar con datos reales.

El más obvio es la sensibilidad a los parámetros. Modificar n , s , M o τ puede mover la primera detección unos días en una u otra dirección, y no hay un criterio universal para fijarlos: ventanas cortas pierden estructura, ventanas largas mezclan regímenes. En la práctica se exploran varias combinaciones y se valida el resultado sobre los propios datos.

La resolución temporal es otra limitación clara. La detección queda asociada al intervalo cubierto por dos ventanas consecutivas, lo que con la configuración elegida se traduce en una incertidumbre de varias semanas. Reducir el paso s mejora ese margen, pero a costa de multiplicar el número de cálculos, aumentando el coste computacional de manera considerable: cada ventana requiere construir una filtración de Vietoris–Rips y reducir su matriz de borde, y aunque `ripser` hace ese cálculo manejable, sigue estando lejos del de un test clásico de cambio de varianza.

Hay una última limitación: cuando la transición se reparte a lo largo de muchas ventanas, las distancias bottleneck consecutivas pueden quedarse siempre pequeñas y el detector no producir ningún pico. El pinchazo de la burbuja punto-com es el ejemplo más claro de este caso.

A pesar de todo, el experimento sostiene la idea central del trabajo. Aplicado a una serie financiera real con un cambio documentado, el procedimiento identifica el cambio sin etiquetas externas ni entrenamiento previo, y lo hace a partir de la geometría local de las nubes de retardos, no de la varianza ni de la autocorrelación. Que esa señal coincida cualitativamente con el inicio del deterioro previo a los grandes movimientos del mercado es probablemente la mejor ilustración de lo que la topología puede aportar al análisis de series temporales.

9 Conclusiones y trabajo futuro

En este trabajo se ha estudiado la detección de cambios de régimen en series temporales desde el punto de vista del análisis topológico de datos. La idea de partida ha sido transformar fragmentos locales de una serie temporal en nubes de puntos y analizar cómo cambia su forma a lo largo del tiempo. Para llegar a este procedimiento ha sido necesario construir primero el marco matemático, comenzando por los complejos simpliciales y la homología simplicial, y llegando después a la homología persistente y al embedding por ventanas deslizantes.

A partir de esta base teórica, la parte práctica ha permitido comprobar el comportamiento del método en distintos contextos. En el Capítulo 7 se han considerado tres escenarios sintéticos, en los que el instante de cambio era conocido de antemano. Estos experimentos han mostrado que el procedimiento es capaz de detectar tanto la desaparición como la aparición de estructura periódica, con una precisión limitada por la longitud de la ventana móvil utilizada.

En el Capítulo 8 se ha aplicado el mismo procedimiento al índice S&P 500 alrededor de la crisis financiera de 2008. La fecha detectada aparece unas semanas antes de la quiebra de Lehman Brothers, en una zona temporal compatible con el deterioro progresivo de la liquidez descrito en la literatura financiera. Además, al extender el análisis a otros cinco episodios bursátiles, el método identifica un cambio de régimen en cinco de los seis casos estudiados, normalmente dentro de un margen de pocas semanas respecto al evento de referencia. El caso del pinchazo de la burbuja punto-com queda fuera de este comportamiento, lo que sugiere que el método funciona mejor ante cambios relativamente bruscos que ante transiciones más suaves y prolongadas.

La comparación con un detector clásico basado en la varianza móvil de los retornos también resulta útil. La varianza móvil reacciona antes en algunos casos, pero tiende a generar más falsas alarmas en tramos estacionarios. La señal topológica, en cambio, parece más selectiva, aunque puede responder con más retraso cuando la transición es gradual. Por tanto, los resultados no apuntan a sustituir un enfoque por otro, sino más bien a combinarlos. La información topológica puede aportar una lectura complementaria a los descriptores estadísticos clásicos.

Limitaciones

El procedimiento presenta varias limitaciones. En primer lugar, la elección de los parámetros del embedding y de la ventana móvil influye de manera clara en los resultados. No existe un criterio universal para fijar estos valores, por lo que una parte del análisis depende de pruebas previas y de la naturaleza de la serie estudiada. En segundo lugar, el umbral robusto utilizado presupone que el tramo de referencia tiene un comportamiento aproximadamente estacionario. Esta hipótesis puede no cumplirse en todas las aplicaciones reales. Por último, el cálculo de diagramas de persistencia tiene un coste computacional mayor que el de otros detectores clásicos, aunque en los experimentos

realizados ha sido manejable gracias a implementaciones eficientes como `ripser`.

Trabajo futuro

Como continuación natural del trabajo, una primera línea sería estudiar otras representaciones de los diagramas de persistencia, como las *persistence images* o los *persistence landscapes*. Estas representaciones transforman los diagramas en descriptores numéricos más fáciles de comparar o introducir en modelos estadísticos, y podrían ayudar a captar mejor transiciones graduales como la observada en el caso de la burbuja punto-com.

Una segunda línea consistiría en combinar la señal topológica con detectores clásicos, por ejemplo con la varianza móvil de los retornos. Un esquema híbrido podría aprovechar la rapidez de respuesta de los métodos estadísticos y la mayor selectividad de la señal topológica. Esto permitiría construir detectores más estables y menos dependientes de una única medida.

Finalmente, sería interesante aplicar el procedimiento a datos intradía. En este tipo de datos, los cambios en la microestructura del mercado pueden aparecer antes y con mayor detalle que en las series de cierre diario. Esto permitiría comprobar si el enfoque topológico detecta señales más tempranas o más precisas cuando se trabaja a una escala temporal más fina.

Reflexión final

Una de las partes más interesantes del trabajo ha sido ver cómo se conectan áreas que, durante el grado, suelen estudiarse por separado. La topología algebraica, que en un primer momento puede parecer muy abstracta, aparece aquí como una herramienta concreta para analizar datos. El álgebra lineal sobre $\mathbb{F}_2$ se convierte en la base del algoritmo que calcula los diagramas de persistencia, y el análisis de series temporales se relaciona con ideas procedentes de los sistemas dinámicos a través del Teorema de Takens 5.1.

Más allá de los resultados concretos obtenidos, el trabajo muestra que la información geométrica y topológica puede aportar una perspectiva útil en el análisis de series temporales. No resuelve por sí sola el problema de detectar cambios de régimen, pero sí ofrece una forma distinta de observar la evolución local de una señal.

Bibliografía

- [1] Gunnar Carlsson. Topology and data. *Bulletin of the American Mathematical Society*, 46(2):255–308, 2009.
- [2] Frédéric Chazal, Clément Levrard, and Martin Royer. Topological analysis for detecting anomalies (TADA) in dependent sequences: application to time series. *Journal of Machine Learning Research*, 25:1–49, 2024.
- [3] David Cohen-Steiner, Herbert Edelsbrunner, and John Harer. Stability of persistence diagrams. *Discrete & Computational Geometry*, 37(1):103–120, 2007.
- [4] Herbert Edelsbrunner and John Harer. *Computational Topology: An Introduction*. American Mathematical Society, Providence, Rhode Island, 2010.
- [5] Herbert Edelsbrunner, David Letscher, and Afra Zomorodian. Topological persistence and simplification. *Discrete & Computational Geometry*, 28(4):511–533, 2002.
- [6] Robert Ghrist. Barcodes: The persistent topology of data. *Bulletin of the American Mathematical Society*, 45(1):61–75, 2008.
- [7] Allen Hatcher. *Algebraic Topology*. Cambridge University Press, 2002.
- [8] Jose A. Perea. Topological time series analysis. *Notices of the American Mathematical Society*, 66(5):686–694, 2019.
- [9] Jose A. Perea and John Harer. Sliding windows and persistence: An application of topological methods to signal analysis. *Foundations of Computational Mathematics*, 15:799–838, 2015.
- [10] Floris Takens. Detecting strange attractors in turbulence. In David Rand and Lai-Sang Young, editors, *Dynamical Systems and Turbulence, Warwick 1980*, volume 898 of *Lecture Notes in Mathematics*, pages 366–381. Springer, 1981.
- [11] Afra Zomorodian and Gunnar Carlsson. Computing persistent homology. *Discrete & Computational Geometry*, 33(2):249–274, 2005.